

Design a threat detection platform using AI and XDR
تصميم منصة لاكتشاف التهديدات باستخدام الذكاء الاصطناعي وXDR

تقرير مشروع - هندسة أمن الأنظمة والشبكات

اعداد:

يامن حاجين

جاد كنذر

اشراف:

د. وسيم الجنيدي

آب / أغسطس 2025

الخلاصة

في ظل التحول الرقمي المتسارع وتصادد حدة التهديدات الإلكترونية، تواجه المؤسسات تحديات غير مسبوقة في حماية أصولها الرقمية. لم تعد أنظمة إدارة المعلومات والأحداث الأمنية (SIEM) التقليدية كافية لمواكبة التعقيد المتزايد لهذه التهديدات. في هذا المشروع، سنناقش رؤية متكاملة لتعزيز أنظمة الدفاع السيبراني من خلال الدمج الاستراتيجي بين تقنيات الذكاء الاصطناعي المتطورة والبنية التحتية القائمة لأنظمة SIEM. سيتناول البحث إطاراً نظرياً شاملاً يغطي الأسس العلمية لأنظمة كشف التسلل (IDS) وتطورها التاريخي، مع تحليل معمق للتحولات الجوهرية في أنظمة SIEM عبر العقد الماضي. كما سيناقد الأسس النظرية والتطبيقية للذكاء الاصطناعي والتعلم الآلي، مع التركيز على تطبيقاتها الثورية في مجال الأمن السيبراني. سيعتمد المشروع على منهجية بحثية متكاملة تشمل دراسة تحليلية لأكثر من 20 دراسة مرجعية رائدة تغطي الفترة من 2015 إلى 2024، مع تحليل نقدي للتحديات التقنية والعملية التي تواجه عملية الدمج هذه. على الصعيد التطبيقي، سيقوم المشروع بتصميم وتنفيذ نموذج عملي متقدم للكشف الاستباقي عن الهجمات، مع ضمان تحقيق تكامل سلس وفعال مع البنية التحتية القائمة. يهدف هذا البحث إلى تقديم إسهام علمي وعملي ملموس في مجال الأمن السيبراني، من خلال إثبات جدوى التحول من النموذج التفاعلي التقليدي إلى النموذج الاستباقي الذكي، وإبراز الدور التحويلي للذكاء الاصطناعي في إعادة صياغة مستقبل أنظمة الدفاع السيبراني. كما يسعى إلى تقديم إطار عمل متكامل يمكن للمؤسسات الاعتماد عليه في رحلتها نحو التحول الرقمي الآمن.

الكلمات المفتاحية: الأمن السيبراني، أنظمة SIEM، الذكاء الاصطناعي، التعلم الآلي، كشف التسلل، كشف الشذوذ، الأمن الاستباقي، التحول الرقمي، إدارة المخاطر السيبرانية.

جدول المحتويات

المقدمة:	
المقدمة:	1.....
المشكلة العلمية:	2.....
أهداف المشروع:	4.....
الدراسة مراجعة:	5.....
التحديات:	14.....
التطبيقات العملية:	16.....
الفصل الأول: الدراسة النظرية	18.....
1.1 لمحة شاملة عن كشف الاختراقات	19.....
1.1.1 مفهوم وأهمية كشف التسلل	19.....
1.1.2 نظرة تاريخية حول كشف التسلل	19.....
1.1.3 النماذج الأساسية للكشف	20.....
1.1.3.1 كشف إساءة الاستخدام (الكشف القائم على التوقعات)	20.....
1.1.3.2 كشف الشذوذ (الكشف القائم على السلوك)	22.....
1.1.4 تصنيف أنظمة كشف التسلل	23.....
1.1.4.1 تصنيف مصدر البيانات	23.....

24.....	1.1.4.2 نماذج النشر المعمارية.....
24.....	1.1.4.3 منهجيات التحليل.....
25.....	1.1.5 عملية كشف التسلل العامة (إطار عمل مختصر).....
26.....	1.1.6 التحديات الأساسية في كشف التسلل.....
27.....	1.1.7 التطور و الاتجاهات المستقبلية في كشف التسلل.....
28.....	1.1.8 اعتبارات التنفيذ و أفضل الممارسات.....
29.....	1.1.9 الخاتمة.....
30.....	1.2 لمحة شاملة عن الذكاء الاصطناعي.....
30.....	1.2.1 تعريف الذكاء الاصطناعي.....
30.....	1.2.2 لمحة تاريخية.....
32.....	1.2.3 أهمية الذكاء الاصطناعي.....
33.....	1.2.4 أنواع الذكاء الاصطناعي.....
34.....	1.2.5 المكونات الأساسية للذكاء الاصطناعي.....
36.....	1.2.6 الذكاء الاصطناعي في التطبيقات الواقعية.....
37.....	1.2.7 الآثار الأخلاقية و الاجتماعية للذكاء الاصطناعي.....
38.....	1.2.8 الافاق المستقبلية في الذكاء الاصطناعي.....
38.....	1.2.9 الخاتمة.....
39.....	1.3 لمحة شاملة عن SIEM.....

39.....	1.3.1 تعريف و نطاق SIEM
41.....	1.3.2 دور SIEM في ضمان الأمان
43.....	1.3.3 نظرة تاريخية حول أنظمة SIEM
45.....	1.3.4 المفاهيم الأساسية في أنظمة SIEM
47.....	1.3.5 مكونات نظام SIEM الفعال
50.....	الفصل الثاني:تجهيز بيئة العمل
51.....	2.1 مقدمة عامة
51.....	2.2 نظام التشغيل Linux Ubuntu
54.....	2.3 منظومة SIEM
56.....	2.4 جدار الحماية PfSense
57.....	2.5 الأداة Sysmon
61.....	الفصل الثالث:الحل المقترح
62.....	3.1 مقدمة عامة للفصل
62.....	3.2 بنية الحل المقترح
63.....	3.3 شرح الية عمل الخوارزمية (isolation forest)
63.....	3.3.1 الفكرة الرئيسية
65.....	3.4 تجهيز البنية الشبكية و العملية
66	3.5 الربط بين Pfsense و Wazuh server

3.6	تهيئة القواعد و Decoders	67
3.7	تنفيذ هجمة (BRUTE FORCE) SSH لأختبار القواعد العادية (بدون ذكاء اصناعي)	68
3.8	النقاط السجلات و توليد الإنذارات	69
3.9	إعداد وربط wazuh agent مع wazuh manager	70
3.10	جمع ومراقبة سجلات Sysmon على نظام windows	71
3.11	مرحلة جمع وتحليل السجلات الأمنية باستخدام wazuh	72
3.12	تحويل سجلات Sysmon الخام إلى dataset	73
3.13	مرحلة ترميز البيانات واستخراج الميزات	75
3,14	مرحلة تدريب نموذج كشف الشذوذ باستخدام isolation forest	77
3.15	الكشف عن السلوك الشاذ بأستخدام الذكاء الاصطناعي	81
3.16	خاتمة الفصل	81
الفصل الرابع: النتائج والمقارنات		83
4.1	مقدمة عامة للفصل	84
4.2	عرض و تحليل النتائج	85
4.2.1	الكفاءة التشغيلية و الأداء	86
4.2.2	فعالية التكامل مع منصة Wazuh	86
4.2.3	مقارنة مع الأسلوب التقليدي	87
4.3	تحليل النتائج	87

4.4	التحديات العملية اثناء التنفيذ.....	88
4.4.1	جودة وتمثيل البيانات.....	88
4.4.2	التكامل مع البنية التحتية القائمة.....	88
4.4.3	ضبط معاملات النموذج.....	88
4.4.4	الأداء والحوسبة.....	89
4.4.5	القابلية للتفسير.....	89
5	التوصيات.....	89
5.1	التوصيات التنفيذية.....	89
	الخاتمة.....	89
	الافاق المستقبلية للتطوير.....	91
	المراجع.....	92

فهرس الجداول

	جدول الدراسة المراجعة.....	7
2.1	مقارنة Ubuntu مع Kali linux.....	53
2.2	مقارنة Wazuh مع Splunk SIEM.....	55
2.3	مقارنة pfSense مع CiscoASA.....	57

4.1 المقارنة مع الأسلوب التقليدي.....87

فهرس الأشكال

1.1 أنواع أنظمة كشف التسلل.....	26
1.2 أنواع الذكاء الاصطناعي.....	35
1.3 مكونات نظام SIEM الفعال.....	49
3.1 آلية عمل خوارزمية isolation forest.....	64
3.2 بنية النظام.....	65
3.3 الربط بين wazuh و pfsense.....	66
3.4 القواعد و Decoders.....	67
3.5 تنفيذ الهجمة.....	68
3.6 توليد الإنذارات.....	69
3.7 wazuh agent.....	70
3.8 عرض سجلات Sysmon.....	71
3.9 ملفات سجلات wazuh المخزنة ضمن مجلد archive.....	72
3.10 كود استخراج البيانات من سجلات son وتحويلها إلى csv.....	74
3.11 كود تحويل البيانات الخام إلى ميزات عديدة وتجميعها ضمن نوافذ زمنية.....	76
3.12 كود تدريب الخوارزمية واكتشاف السلوك الشاذ.....	80

3.13 ناتج اكتشاف الأنشطة الشاذة باستخدام نموذج الذكاء الاصطناعي.....81

4.1 نتائج خوارزمية التدريب.....85

المقدمة

المقدمة

في ظل المشهد المتسارع لتطور الأمن السيبراني اليوم، تواجه المؤسسات عدداً متزايداً باستمرار من التهديدات، بدءاً من الهجمات السيبرانية المعقدة وصولاً إلى المخاطر الداخلية. ولمواجهة هذه التحديات بفاعلية، تحتاج الشركات إلى رؤية فورية في بيئات تقنية المعلومات الخاصة بها، واكتشاف سريع للتهديدات، واستجابة منسقة للحوادث. وهنا يبرز الدور المحوري لأنظمة إدارة معلومات وأحداث الأمن.

توفر حلول الـ SIEM جمعاً مركزياً للسجلات وربطها وتحليلها، مما يمكن فرق الأمن من اكتشاف الشذوذات، والتحقيق في الحوادث، والامتثال للمتطلبات التنظيمية. ومن خلال تجميع البيانات من الشبكات والخوادم والتطبيقات والأجهزة الأمنية، تساعد أنظمة SIEM على تحديد الأنشطة الخبيثة، وتقليل أوقات الاستجابة، وتعزيز الموقف الأمني العام.

تاريخياً، ركزت أنظمة SIEM على تجميع البيانات الأمنية، لكنها واجهت صعوبة في تحليل مجموعات البيانات الضخمة والمعقدة بشكل فعال. وقد أحدث دمج الذكاء الاصطناعي، وخاصة التعلم الآلي والتعلم العميق، في أدوات SIEM ثورة في مجال الأمن السيبراني عبر تمكين القدرات التنبؤية [37]. تعتمد أنظمة SIEM المدعومة بالذكاء الاصطناعي على خوارزميات متقدمة لتحليل البيانات التاريخية والفورية، والتعرف على الأنماط، والتنبؤ بالتهديدات المحتملة [2].

هذا التحول من مجرد الاكتشاف إلى الصيد الاستباقي للتهديدات يتيح للمؤسسات معالجة نقاط الضعف والتخفيف من المخاطر قبل أن تتصاعد إلى هجمات شاملة. يستعرض هذا التقرير الدور التحويلي للذكاء الاصطناعي في أنظمة SIEM، مسلطاً الضوء على كيفية تعزيز الذكاء التنبؤي لعمليات الكشف عن التهديدات، والكفاءة التشغيلية، والاستجابة للحوادث. كما يتناول تطبيقات واقعية لأنظمة SIEM المدعومة

بالذكاء الاصطناعي في الصيد الاستباقي للتهديدات والتخفيف من المخاطر، مبرزاً أهميتها الجوهرية في أطر الأمن السيبراني الحديثة. ومن خلال اعتماد هذه الأدوات المتقدمة، يمكن للمؤسسات بناء مرونة أكبر في مواجهة التهديدات المتطورة وحماية أصولها الرقمية بشكل أكثر فاعلية.

المشكلة العلمية

- مع التطور المتسارع في الهجمات السيبرانية، أصبحت الأنظمة التقليدية المعتمدة على القواعد (Rule-based Systems) غير كافية لاكتشاف التهديدات الحديثة [3]، خاصة تلك التي تعتمد على تقنيات متقدمة مثل التهرب (Evasion) أو الهجمات غير المعروفة (Zero-day Attacks).
 - تعتمد أنظمة SIEM التقليدية على قواعد ثابتة لتحليل السجلات (Logs)، مما يؤدي إلى مشكلتين رئيسيتين:
 - ارتفاع عدد الإنذارات الكاذبة (False Positives) [4].
 - عدم القدرة على اكتشاف السلوك غير الطبيعي الذي لا يطابق قواعد معروفة
 - بالإضافة إلى ذلك، فإن الاعتماد على مصدر بيانات واحد (مثل Logs النظام فقط) يحد من القدرة على تحليل السياق الكامل للهجوم.
 - لذلك، تكمن المشكلة العلمية في الحاجة إلى نظام ذكي قادر على:
 - تحليل سلوك النظام بدلاً من الاعتماد فقط على القواعد
 - اكتشاف الأنشطة غير الطبيعية حتى في غياب توقيع معروف
 - دمج البيانات من عدة مصادر (Endpoint + Network) ضمن إطار موحد [1].
- وهو ما يقود إلى مفهوم XDR (Extended Detection and Response) الذي يهدف إلى توحيد مصادر البيانات وتحليلها بشكل متكامل باستخدام تقنيات الذكاء الاصطناعي. لقد أحدث تطور الذكاء

الاصطناعي ثورة في مجال الأمن السيبراني، مقدماً مزايا دفاعية كبيرة[1]. غير أن هذا التقدم التكنولوجي ذاته يمثل، بشكل مفارق، محفزاً محتملاً لظهور تهديدات سيبرانية أكثر تطوراً، مثل الهجمات السيبرانية المدعومة بالذكاء الاصطناعي[5].

ففي الأيدي الخطأ، أصبح الذكاء الاصطناعي أداة بالغة الخطورة تُستخدم لأتمتة التهديدات السيبرانية وتعزيز فعاليتها. إذ يستغل مجرمو الإنترنت قدرات الذكاء الاصطناعي للتكيف بسهولة مع التدابير الدفاعية، وتنفيذ الهجمات بسرعات غير مسبوقة، واستغلال الثغرات بدقة متناهية. كما يمكن الذكاء الاصطناعي المهاجمين من محاكاة السلوك البشري، مما يزيد من فاعلية هجمات التصيد الاحتيالي ويرفع احتمالية نجاحه[5]. إضافة إلى ذلك، يساعد الذكاء الاصطناعي في تطوير برمجيات خبيثة "ذكية"، قادرة على التعلم من بيئتها، وتكييف استراتيجياتها لتجنب الاكتشاف، وإلحاق أقصى قدر من الضرر. هذا المستوى من التعقيد يجعل الدفاعات الأمنية التقليدية، مثل الكشف عن البرمجيات الخبيثة بالاعتماد على التوقعات، غير كافية في مواجهة هذه التهديدات المتقدمة. ويُعد **DeepLocker**، الذي ابتكرته شركة IBM Research ، مثالاً بارزاً على هذا التهديد الناشئ[6]. فهو يمثل جيلاً جديداً من أدوات الهجوم المستهدفة شديدة التخفي والمدعومة بالذكاء الاصطناعي. إذ يُخفي نواياه الخبيثة إلى أن يصل إلى ضحيته المحددة، مما يجسد مدى التطور المستقبلي المحتمل للتهديدات البرمجية.

وقد أصبح التعامل مع الثغرات الأمنية أكثر صعوبة من أي وقت مضى. فالأساليب التفاعلية التقليدية التي كانت تتبناها أنظمة SIEM القديمة تنتظر استغلال الثغرات قبل معالجتها، وهو نهج أثبت قصوره في مشهد الأمن السيبراني الحالي.

اهداف المشروع

يهدف هذا المشروع إلى تصميم وتنفيذ نظام أمني متكامل يعتمد على مفهوم XDR، ويجمع بين تقنيات SIEM والذكاء الاصطناعي لتحسين قدرات الكشف والاستجابة للتهديدات السيبرانية.

وتشمل أهداف المشروع ما يلي:

- 1- بناء بيئة SIEM باستخدام Wazuh لجمع وتحليل السجلات الأمنية.
- 2- تفعيل جمع بيانات Endpoint باستخدام Sysmon للحصول على معلومات تفصيلية عن العمليات والأنشطة داخل النظام.
- 3- دمج بيانات الشبكة باستخدام pfSense لتوفير رؤية أوسع لسلوك الشبكة.
- 4- إنشاء Dataset حقيقي من سجلات النظام تمثل السلوك الطبيعي للمستخدم.
- 5- معالجة البيانات وتحويلها إلى صيغة مناسبة للتحليل باستخدام تقنيات Feature Engineering و Encoding.
- 6- تطبيق نموذج ذكاء اصطناعي باستخدام Isolation Forest للكشف عن السلوك غير الطبيعي (Anomaly Detection).
- 7- تقييم أداء النموذج باستخدام مقاييس مثل Accuracy و Precision و Recall.
- 8- محاكاة سيناريوهات هجوم بسيطة (مثل استخدام PowerShell أو أوامر مشبوهة) وتحليل قدرة النظام على اكتشافها.
- 9- تقديم نموذج أولي (Prototype) لنظام XDR قادر على:

. جمع البيانات من عدة مصادر

. تحليلها باستخدام الذكاء الاصطناعي

. اكتشاف التهديدات بشكل شبه فوري

. تقليل الاعتماد على القواعد الثابتة والانتقال نحو التحليل السلوكي الذكي.

الدراسة المراجعة

شهدت أنظمة إدارة معلومات وأحداث الأمن (SIEM) تطورات كبيرة خلال الفترة بين عامي 2015 و2024، حيث انتقلت من الأساليب التقليدية إلى مناهج تنبؤية مدعومة بالذكاء الاصطناعي. ففي عام 2015، أجرى **Buczak & Guven** دراسة شاملة حول تطبيقات التعلم الآلي في الأمن السيبراني، مسلطين الضوء على خوارزميات مثل آلات المتجهات الداعمة (SVM)، (Decision Trees)، (Random Forests) في مجال كشف التسلسل ودمجها ضمن أنظمة SIEM. وقد أسس ذلك لانتقال تدريجي من الأنظمة القائمة على القواعد إلى التحليلات الأمنية المدعومة بالتعلم الآلي.

بحلول عام 2016، ركّز **Garcia-Teodoro** وآخرون على تحسين دقة أنظمة SIEM باستخدام تقنيات التصنيف المعتمدة على ML، بينما قدّم **Chandola** وآخرون تقنيات للكشف عن الشذوذ على نطاق واسع للتعامل مع التدفقات الضخمة للبيانات، مما شكّل مقدمة للتحليلات التنبؤية الحديثة في SIEM.

في عام 2017، قام **Almotairi** وآخرون بتطبيق تحليلات سلوك المستخدم والكيان (UEBA) في أنظمة SIEM، مما أتاح الكشف عن الشذوذات اعتماداً على السلوك. وفي الوقت ذاته، شدد **Sommer & Paxson** على أهمية المناهج الهجينة التي تجمع بين الأنظمة القائمة على القواعد و ML، في موازنة الأتمتة مع الخبرة البشرية — وهو مبدأ ما يزال يحتفظ بأهميته في أطر SIEM الحديثة المعتمدة على الذكاء الاصطناعي.

أما في عام 2018، فقد أبر **Shiravi** وآخرون دور تحليلات البيانات الضخمة في أنظمة SIEM، مما مكن من تقليص أزمنة الاستجابة وتحسين الرؤية الأمنية.

وجاء الانطلاقة الكبرى في عام 2020 حين قام **Santos** وآخرون بدمج تقنيات التعلم العميق في أنظمة SIEM، الأمر الذي ساهم في تحسين دقة كشف الشذوذ بشكل ملحوظ وخفض معدلات الإيجابيات الكاذبة — وهو ما مهّد الطريق نحو الجيل الجديد من أنظمة SIEM المدعومة بالذكاء الاصطناعي.

وفي عام 2022، استخدم **Rahman** وآخرون تقنيات التعلم العميق للكشف عن التهديدات المستمرة المتقدمة (APT)، بينما قدّم **Yamin** وآخرون نموذج SIEM استباقياً يعتمد على الذكاء الاصطناعي التكميلي، مما مثّل انتقالاً من الاكتشاف إلى التنبؤ.

بحلول عام 2023، حدّد **Sarker** أساليب التعلم الآلي التجميعي (Ensemble ML) باعتبارها الأكثر تطوراً في تقليل الإيجابيات الكاذبة، في حين قام **Barker & Shiaeles** بأتمتة عمليات مراكز عمليات الأمن (SOC) باستخدام التحليلات التنبؤية، محوّلين أنظمة SIEM إلى أداة دفاع استباقية.

وأخيراً، في عام 2024، طوّر **Lyu** وآخرون إطاراً يجمع بين التعلم العميق والتحليلات السلوكية، ليمثل أحدث ما توصلت إليه التقنيات من حيث الدقة التنبؤية وتقليل الضوضاء.

تُبرز هذه المسيرة التطورية رحلة أنظمة SIEM من مجرد تحليل تفاعلي للسجلات إلى منصات أمنية تنبؤية مدعومة بالذكاء الاصطناعي، بما يتماشى مع أهداف الأمن السيبراني الحديثة المتمثلة في الصيد الاستباقي للتهديدات والاستجابة المؤتمتة.

وفي مايلي ملخص لما سبق :

جدول الدراسة المراجعة

المرجع	العلاقة مع مشروعنا	النتيجة	المؤلفون	البحث
[7]	يمكن أن يُعتبر هذا العمل مرجعاً أساسياً يوضح كيف تطورت أنظمة SIEM من التعلم الآلي	أبرزوا أن الأساليب الأكثر تقدماً في ذلك الوقت شملت SVM، وأشجار القرار (Decision	Buczak & Guven	استطلاع لأساليب التنقيب عن البيانات والتعلم الآلي في كشف التسلل الأمني السيبراني

		الكلاسيكي إلى الذكاء الاصطناعي التنبؤي. لاكتشاف التسلل ودمجها في أنظمة SIEM.	
كشف التسلل الشبكي القائم على الشذوذ: التقنيات، الأنظمة، والتحديات	Garcia- Teodoro et al	حددت الدراسة أن التعلم الآلي المعتمد على التصنيف كان الأسلوب الأكثر تقدماً لتعزيز دقة أنظمة SIEM في ذلك الوقت.	يوفر نظرة ثاقبة على التحسينات المبكرة في التعلم الآلي قبل الانتقال إلى التعلم العميق.
كشف الشذوذ في التسلسلات المنفصلة:	Chandola et al	كان الكشف عن الشذوذ على نطاق واسع يُعتبر الأسلوب	يُعدّ مهماً كمقدمة للكشف التنبؤي عن الشذوذ في

دراسة استقصائية		الأكثر تقدماً في معالجة مشكلة انفجار البيانات.	أنظمة SIEM المدعومة بالذكاء الاصطناعي.	
نهج متعدد الطبقات لتحديد السلوكيات الخبیثة في حركة مرور الشبكة	Almotairi et al	أصبح تحليل سلوك المستخدم والكيان (UEBA) هو الأسلوب الأكثر تقدماً للكشف عن الشذوذات في سلوك المستخدمين والكيانات.	وضع الأساس للتحليل السلوكي، والذي يُعدّ ميزة رئيسية في أنظمة SIEM التنبؤية الحديثة.	[10]
خارج العالم المغلق: حول استخدام التعلم	Sommer & Paxson	اعتُبرت الطرق الهجينة الأكثر تقدماً لأنها توفر	ذو صلة مباشرة، حيث تطورت أطر SIEM الهجينة	[11]

الآلي لاكتشاف التسلل الشبكي		توازناً بين الخبرة البشرية والأتمتة.	الحديثة المدعومة بالذكاء الاصطناعي من هذا المبدأ.	
التحليلات في الزمن الحقيقي: التقنيات والتطبيقات على تدفقات البيانات الضخمة في مراقبة الأمن	Shiravi et al	مثلت أنظمة SIEM المدفوعة بالبيانات الضخمة الأسلوب الأكثر تقدماً لتقليل زمن الاستجابة وتعزيز الرؤية الأمنية.	نعم، حيث أن مشروعنا يتطلب التعامل مع البيانات الضخمة في الزمن الحقيقي من أجل الصيد الاستباقي للتحديات.	[12]
إدارة معلومات وأحداث الأمن من الجيل	Santos et al	وخلصوا إلى أن هذه الأنظمة تمثل أحدث ما	يمكن استخدام هذا العمل كإطار مرجعي	[13]

القادم: مراجعة منهجية		توصلت إليه إدارة المعلومات الأمنية.	لتصميم نظام SIEM تنبؤي.	
نهج التعلم العميق للكشف عن التهديدات المستمرة المتقدمة في بيانات السحابة	Rahman et al	تم التوصل إلى أن الشبكات العصبية العميقة تمثل الأسلوب الأكثر تقدماً للكشف المبكر عن التهديدات المستمرة المتقدمة (APTs)	نعم، لأن مشروعنا يركز على التنبؤ بالتهديدات قبل حدوثها.	[14]
Adaptive AI-SIEM: نموذج استباقي لإدارة معلومات وأحداث الأمن	Yamin et al	ساهم النظام في تقليل الإنذارات الكاذبة وتحسين القدرة على التكيف مع	يتمشى مع رؤيتنا في الانتقال من الاكتشاف إلى التنبؤ.	[15]

في بيئات تهديدية ديناميكية		التهديدات الجديدة.		
التعلم الآلي لتحليل البيانات الذكي في الأمن السيبراني: مراجعة معاصرة لتقنيات التعلم التجميعي	sarker	عززت هذه المناهج الدقة وقّلت الإيجابيات الكاذبة في أنظمة SIEM.	يمكن لأساليب التجميع (Ensemble) زيادة موثوقية نظامنا.	[16]
نحو مركز عمليات أمن مستقل: إطار تنبؤي بالذكاء الاصطناعي لإدارة معلومات وأحداث الأمن	Barker & Shiaeles	حوّل هذا الابتكار أنظمة SIEM من أداة تفاعلية إلى آلية دفاعية استباقية ومؤتمتة.	يمكن أن يدعم ذلك هدفنا في تقليل زمن الاستجابة من خلال الأتمتة.	[17]

نموذج هجيني للتحليلات السلوكية العميقة لتقليل الإيجابيات الكاذبة في أنظمة SIEM من الجيل القادم	Lyu et al	تم الاعتراف بهذا الإطار باعتباره الأكثر تقدماً في تحسين الدقة التنبؤية في الكشف عن التحديات.	لأنه يدعم بشكل مباشر هدفنا المتمثل في التنبؤ وتقليل الضوضاء.	[18]
---	------------------	---	--	-------------

التحديات

رغم الفوائد العديدة التي يقدمها هذا المشروع إلا أنَّ هناك مجموعة من التحديات التي قد يواجهها أي شخص يعمل عليه ومن أبرز هذه التحديات:

1. تعقيد وجودة البيانات

- **الحجم والوضوء:** تتطلب أنظمة SIEM المدعومة بالذكاء الاصطناعي مجموعات بيانات ضخمة من أجل تحليل دقيق، غير أن البيانات منخفضة الجودة بكثرة (مثل الإنذارات الكاذبة أو السجلات غير ذات الصلة) قد تحجب التهديدات الحقيقية وتضعف فعالية النماذج (الصفحة 2).
- **العزلة البياناتية: (Data Silos)** إن تجزؤ مصادر البيانات (السحابة، البنية التحتية المحلية، إنترنت الأشياء) يعيق التحليل الشامل، ويحدّ من القدرات التنبؤية للذكاء الاصطناعي.

2. القيود الخوارزمية

- **الإيجابيات/السلبات الكاذبة:** الاعتماد المفرط على البيانات التاريخية قد يؤدي إلى فشل الذكاء الاصطناعي في اكتشاف التهديدات الجديدة (هجمات اليوم-صفر)، أو توليد إنذارات خاطئة، مما يضعف الثقة بالنظام.
- **مشكلة “الصندوق الأسود”:** “تفتقر نماذج التعلم الآلي والتعلم العميق المعقدة إلى الشفافية، مما يصعّب عملية تدقيق القرارات أو شرح التنبيهات لأصحاب المصلحة (مثل فرق الامتثال).

3. الموارد والمتطلبات التشغيلية

- **الكثافة الحسابية:** يتطلب التحليل في الزمن الحقيقي قدرة معالجة عالية، مما يؤدي إلى ارتفاع تكاليف الحوسبة والسحابة.

- **فجوات المهارات:** يمثل نقص الكفاءات المتخصصة في كل من الأمن السيبراني والذكاء الاصطناعي/التعلم الآلي عائقاً أمام النشر والضبط الأمثل للنماذج.

4. التهديدات العدائية

- **الهجمات المدعومة بالذكاء الاصطناعي:** يستغل مجرمو الإنترنت الذكاء الاصطناعي لتطوير برمجيات خبيثة مراوغة (مثل *DeepLocker*) تتجاوز الدفاعات التقليدية، مما يفرض الحاجة إلى إعادة تدريب النماذج بشكل مستمر.
- **تسميم البيانات: (Data Poisoning)** قد يقوم المهاجمون بحقن بيانات ضارة في النظام لتخريب نماذج الذكاء الاصطناعي، مما يؤدي إلى تنبؤات خاطئة بالتهديدات.

5. التكامل وقابلية التوسع

- **التوافق مع الأنظمة القديمة:** غالباً ما يتطلب دمج أنظمة SIEM المدعومة بالذكاء الاصطناعي مع البنية التحتية القديمة تعديلات مخصصة بتكاليف مرتفعة.
- **مشكلات القابلية للتوسع:** يمثل الحفاظ على الأداء عبر الشبكات المتنامية (مثل السحابة الهجينة، إنترنت الأشياء) تحدياً في تخصيص الموارد وإدارتها.

التطبيقات العملية

1. الكشف عن التهديدات ومراقبة محاولات التسلل

- تقوم أنظمة SIEM بتجميع السجلات من جدران الحماية (Firewalls) ، وأنظمة كشف/منع التسلل (IDS/IPS)، والأجهزة الطرفية لاكتشاف السلوك غير الطبيعي. مثال: اكتشاف التهديدات الداخلية من خلال أنماط تسجيل دخول غير اعتيادية.

2. الاستجابة للحوادث والتحقيق الجنائي الرقمي (Forensics)

- يتيح التجميع المركزي للسجلات إجراء تحليلات جنائية سريعة بعد حوادث الاختراق. مثال: تحسين تدفقات العمل في التحقيقات الجنائية الرقمية بمساعدة SIEM، مما يقلل زمن الاستجابة بنسبة تصل إلى 45%.

3. الامتثال والجاهزية للتدقيق

- تعتمد المؤسسات على أنظمة SIEM للامتثال لمعايير مثل GDPR، و HIPAA، و PCI-DSS من خلال توفير تقارير مؤتمتة. مثال: نشر أنظمة SIEM في قطاع الرعاية الصحية لضمان الامتثال لمتطلبات HIPAA.

4. أمن السحابة والبنى التحتية الهجينة

- تدمج أنظمة SIEM الحديثة مع منصات مثل **AWS** و**Azure** والهياكل الهجينة لتحقيق رؤية موحدة. مثال: أنظمة SIEM السحابية الأصلية (Cloud-native) التي تدعم خطوط أنابيب

.DevSecOps

5. حماية البنى التحتية الحيوية

- تُطبّق في شبكات الطاقة، ووسائل النقل، وقطاع الرعاية الصحية لمنع الاضطرابات السيبرانية-الفيزيائية. مثال: نشر SIEM في الشبكات الذكية (Smart Grids) لاكتشاف الشذوذات.

6. تحليلات سلوك المستخدم والكيان (UEBA)

- تكشف أنظمة SIEM المدعومة بالتعلم الآلي الحسابات المخترقة والتهديدات الداخلية. مثال : SIEM مدمج مع UEBA ينجح في اكتشاف محاولات تصعيد الامتيازات.

7. التكامل مع SOAR (تنسيق وأتمتة واستجابة الأمن)

- تعمل التدفقات المؤتمتة التي يتم تفعيلها بواسطة تنبيهات SIEM على تقليل إرهاق المحللين. مثال : الاستجابة المؤتمتة لرسائل التصيّد الاحتيالي باستخدام تكامل **SIEM + SOAR**.

8. أمن إنترنت الأشياء (IoT) وإنترنت الأشياء الصناعي (IIoT)

- تُستخدم أنظمة SIEM في بيانات إنترنت الأشياء لمراقبة الاتصالات بين الأجهزة. مثال: نظام SIEM صناعي يكتشف تحديثات البرامج الثابتة (Firmware) الخبيثة.

الفصل الأول: الدراسة النظرية

1.1 لمحة شاملة عن كشف الاختراقات

1.1.1 مفهوم وأهمية كشف التسلل

يمثل كشف التسلل تخصصًا أساسيًا في مجال الأمن السيبراني يركز على مراقبة وتحليل الأحداث داخل أنظمة الكمبيوتر والشبكات لتحديد أدلة على الأنشطة الخبيثة، أو انتهاكات سياسات الأمن، أو محاولات الوصول غير المصرح بها. كمكون حاسم في هياكل الأمن ذات الطبقات المتعددة (دفاع متعمق)، يعمل كشف التسلل على مبدأ "الأختراق المفترض"، معترفًا بأن إجراءات الأمن الوقائية وحدها لا يمكنها توفير حماية كاملة ضد الخصوم المصيرين. الهدف الأساسي من أنظمة كشف التسلل ليس منع الهجمات بشكل مباشر، بل تمكين اكتشافها بشكل فوري، مما يسهل الاستجابة الفعالة للحوادث ويقلل من الضرر المحتمل للأصول التنظيمية والسمعة والعمليات.

تم وضع الأساس النظري لكشف التسلل الحديث من قبل Dorothy E. Denning في عملهم المؤثر عام 1987، الذي صاغ مفهوم كشف التسلل كعملية آلية لتحديد انتهاكات سياسات الأمن من خلال التحليل المنهجي لبيانات التدقيق [19]. قدم هذا الإطار الرائد المفاهيم الأساسية التي لا تزال توجه البحث والتطبيق في كشف التسلل، بما في ذلك أهمية سجلات التدقيق، وملفات تعريف السلوك الطبيعي، وتقنيات كشف الشذوذ. إن الأهمية المستمرة لعمل دينينغ تؤكد على الطبيعة الأساسية لكشف التسلل كتخصص في الأمن السيبراني ودوره الحيوي في الوضع الأمني الشامل.

1.1.2 نظرة تاريخية حول كشف التسلل

يعكس تطور تقنيات كشف التسلل المشهد المتغير لتهديدات الأمن السيبراني والبيئات التكنولوجية. ظهرت أنظمة كشف التسلل المبكرة في الثمانينيات كمشاريع بحثية أكاديمية، مع مساهمات ملحوظة شملت نظام (Intrusion Detection Expert System) IDES في SRI International ونظام (Network Anomaly Detection and Intrusion Reporter) NADIR في مختبر Los

Alamos الوطني. أسست هذه الأنظمة الرائدة العديد من المفاهيم والمناهج الأساسية التي ستوجه التطورات التجارية ومفتوحة المصدر اللاحقة.

شهدت التسعينيات تحويل تقنيات كشف التسلل إلى منتجات تجارية، حيث جلبت منتجات مثل **RealSecure** من Internet Security Systems و **NetRanger** من Cisco قدرات كشف التسلل إلى بيئات المؤسسات. شهدت هذه الفترة أيضًا ظهور بدائل مفتوحة المصدر، وأشهرها **Snort**، والتي عمت الوصول إلى قدرات كشف التسلل وعززت مجتمعًا نابضًا بالمطورين والممارسين الأمنيين. استمر التطور إلى القرن الحادي والعشرين مع دمج وظائف كشف التسلل في منصات أمنية أوسع، بما في ذلك أنظمة إدارة معلومات وأحداث الأمن (**SIEM**) وجدران الحماية من الجيل التالي، مما يعكس التطور المتزايد لكل من التقنيات الدفاعية والتهديدات السيبرانية.

1.1.3 النماذج الأساسية للكشف

يرتكز الأساس النظري والعملية لكشف التسلل على منهجيتين فلسفيتين رئيسيتين لتحديد النشاط الخبيث، لكل منهما خصائصه ونقاط قوته ومحدودياته المميزة. يمثل التمييز بين هذه النماذج مفاضلة أساسية بين الدقة والتغطية، كما نوقش على نطاق واسع في الأدبيات البحثية [20].

1.1.3.1 كشف إساءة الاستخدام (الكشف القائم على التوقعات)

تشكل هذه المنهجية حجر الزاوية في أنظمة كشف التسلل التقليدية وتحظى بنشر واسع نظرًا لموثوقيتها التشغيلية وخصائص أدائها المتوقعة. كنهج قائم على المعرفة، يعتمد كشف إساءة الاستخدام على تقنيات مطابقة الأنماط لتحديد التهديدات المعروفة. تتضمن العملية مقارنة نشاط النظام أو الشبكة المرصود مع قاعدة بيانات شاملة للتوقعات أو الأنماط التي تمثل هجمات معروفة، وثغرات، ومنهجيات استغلال.

تشكل هذه التوقيعات أوصافاً رسمية لتسلسلات الهجوم وقد تشمل تسلسلات **byte** محددة في حزم الشبكة، أو أنماطاً مميزة لاستدعاءات النظام، أو تسلسلات معينة للأحداث تشير إلى نشاط خبيث.

تعتمد الفعالية التشغيلية لأنظمة كشف إساءة الاستخدام بشكل أساسي على جودة وشمولية وتوقيت قواعد بيانات التوقيعات الخاصة بها. تعمل آلية الكشف بشكل أساسي كخوارزمية مطابقة: عندما تتوافق البيانات المرصودة بشكل كافٍ مع نمط في قاعدة المعرفة، يولد النظام إنذاراً. يظهر هذا النهج فعالية خاصة ضد التهديدات المعروفة لأنه يمكن صياغة التوقيعات بدقة عالية لتحديد مؤشرات اختراق محددة. تشمل نقاط قوة كشف إساءة الاستخدام دقته العالية المثبتة في تحديد التهديدات المعروفة، مما يؤدي إلى معدلات منخفضة للإنذارات الإيجابية الكاذبة (**false positives**) التي تجعل الإنذارات قابلة للتنفيذ من قبل المحللين الأمنيين. بالإضافة إلى ذلك، يقدم النهج مزايا كفاءة حسابية، حيث تمثل مطابقة الأنماط عملية مفهومة جيداً وقابلة للتطوير ومناسبة للبيئات عالية الأداء. توفر الإنذارات المنشأة عادةً معلومات محددة حول التهديدات المكتشفة، غالباً ما تحدد أنواع هجمات معينة أو متغيرات برمجيات خبيثة.

ومع ذلك، يعاني كشف إساءة الاستخدام من عدة قيود كبيرة. الأكثر حرجاً، يظهر النهج عجزاً متأسلاً عن اكتشاف الهجمات الجديدة (**Zero-day exploits**) أو حتى تغييرات طفيفة للهجمات المعروفة التي لا يوجد لها توقيع. هذا يخلق نوافذ **vulnerability** حتمية بين ظهور تهديدات جديدة وتوفر توقيعات كشف مقابلة. تعتمد فعالية كشف إساءة الاستخدام بشكل كامل على التحديثات المستمرة وفي الوقت المناسب لقواعد بيانات التوقيعات، مما يمثل عبئاً تشغيلياً كبيراً. علاوة على ذلك، تظل هذه الأنظمة عرضة للتهرب من خلال التقنيات التي تحجب أو تغير أنماط الهجوم (**obfuscate or polymorph**)، بما في ذلك تجزئة الحزم، والتشفير، أو طرق إخفاء التعليمات البرمجية التي تمنع مطابقة الأنماط الناجحة.

1.1.3.2 كشف الشذوذ (الكشف القائم على السلوك)

تمثل هذه المنهجية البديلة نهجًا أكثر طموحًا يهدف إلى التغلب على قيود الأنظمة القائمة على التوقعات (signature-based systems) من خلال التركيز على الشذوذ السلوكي (behavioral abnormalities) بدلاً من الأنماط المعروفة. يعمل كشف الشذوذ من خلال إنشاء نماذج إحصائية أو ملفات تعريف للسلوك الطبيعي للمستخدمين، أو المضيفين، أو التطبيقات، أو الشبكات خلال فترات يُفترض أنها خالية من الهجمات. النشاط اللاحق الذي يظهر انحرافًا إحصائيًا كبيرًا عن هذه الخطوط الأساسية المنشأة يُطلق إنذارات تشير إلى عمليات تسلل محتملة. الافتراض الأساسي الكامن وراء هذا النهج، كما ناقش من قبل Debar et al عام 1999 ، يفترض أن النشاط التسليبي يظهر خصائص مختلفة بشكل ملحوظ عن السلوك الطبيعي [21].

يتضمن تنفيذ أنظمة كشف الشذوذ عادةً مراحل تدريب حيث تقوم مجموعات البيانات المرجعية بإنشاء خطوط أساس سلوكية عبر أبعاد متعددة، بما في ذلك أنماط تسجيل الدخول، واستخدام الأوامر، وأحجام حركة مرور الشبكة، وتوزيعات البروتوكولات، ومقاييس استخدام الموارد. تقيس آلية الكشف بعد ذلك باستمرار الانحراف بين النشاط الحالي والملفات الشخصية المكتسبة باستخدام الطرق الإحصائية، مع إنشاء إنذارات عندما تتجاوز الانحرافات عتبات محددة مسبقًا. تكمن القوة الأساسية لكشف الشذوذ في قدرته النظرية على تحديد الهجمات غير المعروفة سابقًا، بما في ذلك استغلالات zero-day والتهديدات الداخلية المتطورة التي قد تتجنب الكشف القائم على التوقيع. هذه القدرة تجعل كشف الشذوذ ذا قيمة خاصة لتحديد منهجيات الهجوم الجديدة وحسابات الاعتماد الشرعية المخترقة.

على الرغم من مزاياها النظرية، تعاني أنظمة كشف الشذوذ تاريخيًا من تحديات تنفيذ عملية. الأكثر بروزًا، تظهر هذه الأنظمة قابلية واضحة لتوليد أحجام عالية من الإنذارات الإيجابية الكاذبة نظرًا إلى الصعوبة المتأصلة في تعريف السلوك الطبيعي بشكل شامل في بيئات الحوسبة الديناميكية. التغيرات السلوكية المشروعة، مثل عمليات النشر الجديدة للتطبيقات، أو الأنشطة الإدارية غير المعتادة ولكن المصرح بها، أو الاختلافات الموسمية في الأعمال، غالبًا ما تطلق إنذارات كاذبة. هذه الظاهرة غالبًا ما تؤدي إلى إرهاق

الإنذارات (alert fatigue) بين المحللين الأمنيين، مما قد يتسبب في التغاضي عن التهديدات الحقيقية amid العديد من الإنذارات الكاذبة. بالإضافة إلى ذلك، تتطلب أنظمة كشف الشذوذ عادةً موارد حسابية كبيرة للحفاظ على الملف الشخصي والتحليل، وتعتمد فعاليتها بشدة على جودة وتمثيلية بيانات التدريب الأولية.

1.1.4 تصنيف أنظمة كشف التسلل

ما وراء نماذج الكشف الأساسية، يمكن تصنيف أنظمة كشف التسلل وفقًا لأبعاد متعددة، بما في ذلك مصادر البيانات، وهندسات النشر، ومنهجيات التحليل. يوفر فهم هذه التصنيفات نظرة حاسمة حول إمكانيات وقيود مناهج كشف التسلل المختلفة.

1.1.4.1 تصنيف مصدر البيانات

يؤثر اختيار مصادر البيانات بشكل أساسي على قدرات كشف التسلل. تراقب أنظمة كشف التسلل القائمة على الشبكة (NIDS) حركة مرور الشبكة، وتحلل رؤوس وحزم لتحديد النشاط الخبيث. تنتشر هذه الأنظمة عادةً في مواقع شبكية استراتيجية وتوفر رؤية شاملة لاتصالات الشبكة. تعمل أنظمة كشف التسلل القائمة على المضيف (HIDS) على نقاط النهاية الفردية، وتراقب سجلات النظام، وسلامة الملفات، وتغييرات السجل (registry)، والعمليات الجارية. توفر HIDS رؤية عميقة لأنشطة المضيف ولكنها تتطلب النشر والإدارة على الأنظمة المحمية. تركز أنظمة كشف التسلل القائمة على التطبيقات بشكل خاص على أنشطة طبقة التطبيق، وتراقب سجلات المعاملات، وتفاعلات المستخدم، والأحداث الخاصة بالتطبيق. تجمع المناهج الهجينة بين مصادر بيانات متعددة لتحقيق قدرات كشف أكثر شمولاً.

1.1.4.2 نماذج النشر المعمارية

توظف أنظمة كشف التسلل نماذج معمارية مختلفة تؤثر على قابليتها للتطوير وأدائها ومتطلبات إدارتها. تقوم الهياكل المركزية بتحويل جميع بيانات الكشف إلى نقطة تحليل واحدة، مما يبسط الإدارة ولكنه قد يخلق عنق زجاجة في الأداء. تنشر الهياكل الموزعة قدرات التحليل عبر مواقع متعددة، مما يحسن قابلية التطوير ولكن يزيد من تعقيد الإدارة. تنظم الهياكل الهرمية مكونات الكشف في هياكل ذات طبقات، موازنة بين التنسيق المركزي والتحليل الموزع. تستفيد الهياكل القائمة على السحابة من موارد الحوسبة السحابية للتحليل القابل للتطوير، وهي مناسبة بشكل خاص للبيئات التنظيمية الموزعة وحماية البنية التحتية السحابية.

1.1.4.3 منهجيات التحليل

تطورت الأساليب التحليلية المستخدمة في أنظمة كشف التسلل بشكل كبير فاق الثنائية الأساسية لإساءة الاستخدام والشذوذ. تستخدم الطرق الإحصائية نماذج رياضية لتحديد الانحرافات عن الأعراف السلوكية المنشأة. تستخدم التقنيات القائمة على المعرفة المعرفة الأمنية الرسمية، بما في ذلك توقيعات الهجوم ومعلومات الثغرات. تمثل مناهج التعلم الآلي (Machine Learning) أحدث ما توصلت إليه التقنية، مستخدمة خوارزميات تتعلم أنماط الكشف من البيانات التاريخية. تتضمن هذه طرق التعلم الخاضع للإشراف (Supervised Learning) التي تتدرب على مجموعات بيانات مُصنفة، وتقنيات التعلم غير الخاضع للإشراف (Unsupervised Learning) التي تحدد الأنماط في البيانات غير المصنفة، ومناهج شبه خاضعة للإشراف (Semi-Supervised) تجمع بين المنهجين. تتضمن التطورات الحديثة هياكل التعلم العميق (Deep Learning) القادرة على تحديد أنماط معقدة في مساحات البيانات عالية الأبعاد.

1.1.5 عملية كشف التسلل العامة (إطار عمل مختصر)

يتطلب الفهم الشامل لكشف التسلل فحص عملياته التشغيلية، التي تتبع عادةً إطارًا منظمًا يتضمن مراحل متعددة متسلسلة، كما هو مفصل في المراجع الأساسية [22]

تمثل عملية كشف التسلل سلسلة متكاملة تبدأ بجمع البيانات وتنتهي بالاستجابة، وتتكون من المراحل الأساسية التالية:


1. جمع البيانات: مرحلة تجميع البيانات الأولية من المصادر المختلفة مثل سجلات الشبكة والنظم والتطبيقات، والتي تشكل المادة الخام لعملية الكشف.

2. المعالجة المسبقة: تهيئة البيانات للتحليل من خلال تنقيتها وتبويبها واستخلاص السمات الأمنية ذات الدلالة منها، مما يسهل عملية التحليل اللاحقة.

3. التحليل والكشف: تطبيق نماذج الكشف (قائمة على التوقعات أو السلوك) للتعرف على الأنماط غير الطبيعية، مع اتجاه الأنظمة الحديثة لاستخدام أساليب هجينة لتحسين الفعالية.

4. إدارة الإنذارات: توليد إنذارات واضحة وتصنيفها حسب درجة خطورتها وألويتها، تمهيداً لاتخاذ الإجراء المناسب.

5. الاستجابة: احتواء التهديدات المكتشفة عبر إجراءات يدوية أو آلية، مع الحرص على مواءمة مستوى الأتمتة مع طبيعة التهديد وبيئة العمل



1.1 أنواع أنظمة كشف التسلل

1.1.6 التحديات الأساسية في كشف التسلل

1. مغالطة المعدل الأساسي (Base-Rate Fallacy)

تنشأ هذه المشكلة الإحصائية من ندرة الحوادث الأمنية الحقيقية مقارنة بحجم النشاط الطبيعي الهائل. حتى الأنظمة عالية الدقة تُنتج أعداداً كبيرة من الإنذارات الكاذبة، مما يؤدي إلى "إرهاق الإنذارات" (Alert Fatigue) ويهدد بإغفال التهديدات الفعلية [20].

2. حجم البيانات وقيود الأداء

تقرض الكميات الهائلة من البيانات المولدة في البيئات الحديثة ضغوطاً على قدرات الجمع والتخزين والمعالجة. often يتطلب هذا الموازنة بين شمولية المراقبة وأداء النظام، مما قد يخلق فجوات في التغطية.

3. التشفير وقيود الرؤية

يحد انتشار التشفير، رغم أهميته للأمن والخصوصية، من قدرة أنظمة الكشف على فحص المحتوى، مما يعيق بشكل خاص أدوات الكشف التقليدية القائمة على التوقيعات.

4. تقنيات التهرب المتطورة

يطور المهاجمون باستمرار أساليب متقدمة للتهرب من الكشف، مثل البرمجيات متعددة الأشكال والتشفير ومزج الهجمات مع الحركة الشرعية، مما يستلزم تحديثاً مستمراً لأساليب المواجهة.

5. تعقيد التكوين والصيانة

تتطلب هذه الأنظمة ضبطاً دقيقاً للإعدادات وصيانة مستمرة (كالتحديثات المنتظمة للقواعد وإعادة تدريب النماذج) لضمان فعاليتها، مما يشكل عبئاً عملياتياً كبيراً على المنظمات.

1.1.7 التطور والاتجاهات المستقبلية في كشف التسلل

1. دمج الذكاء الاصطناعي والتعلم الآلي

يسهم دمج هذه التقنيات في تعزيز دقة الكشف، خاصة في تحديد الأنماط غير المعروفة سابقاً، والحد من الإنذارات الكاذبة عبر التحليل السياقي المتقدم.

2. الأتمتة والتكامل (SOAR)

تعمل منصات SOAR على تحسين عمليات الاستجابة عبر أتمتة المهام وتنسيقها، مما يسرع احتواء التهديدات ويسهل إدارة الحوادث بشكل فعال.

3. تكامل ذكاء التهديدات

يعزز التكامل مع مصادر الذكاء التهديدي الخارجي قدرة الأنظمة على رصد الهجمات المعروفة والناشئة، مع تحسين دقة تقييم الأولويات.

4. الكشف في البيئات السحابية والقائمة على الحاويات

تتجه الأنظمة نحو دعم البيئات السحابية والحاوية، مع توفير رؤية شاملة وقابلة للتوسع، ومراقبة سلوكيات التطبيقات الحديثة.

5. تقنيات الكشف الحافظة للخصوصية

يتم تطوير تقنيات كشف متوافقة مع متطلبات الخصوصية، مثل تحليل البيانات المشفرة دون فكها، وتقليل جمع البيانات الشخصية.

1.1.8 اعتبارات التنفيذ وأفضل الممارسات

يُعد النجاح في تنفيذ أنظمة كشف التسلل رحلة متكاملة تبدأ بالإعداد الجيد وتستمر بالتحسين المستمر. أولى الخطوات تتمثل في تحقيق الانسجام التام بين النظام والسياسات الأمنية للمؤسسة وأهدافها الاستراتيجية، حيث يجب أن تعكس قواعد الكشف وعتبات الإنذار أولويات العمل ومستوى تقبله للمخاطر.

لا تقل أهمية التخطيط التقني الدقيق عن الجوانب الأخرى، إذ يجب دراسة متطلبات الأداء والشبكة والتخزين بعناية، مع الأخذ في الاعتبار الحاجة للتوسع المستقبلي. ومن الضروري أن يتم دمج النظام بسلاسة مع البنية التحتية الأمنية القائمة، لضمان تبادل المعلومات والتنسيق في الاستجابة للحوادث.

لكن كل هذا يبقى ناقصاً بدون العنصر البشري المؤهل، فاستثمار المؤسسة في تطوير كفاءات فريق الأمن وتدريبه بشكل مستمر يعد عاملاً حاسماً للنجاح. وأخيراً، يجب أن يكون التحسين المستمر منهجية عمل، عبر الاختبار الدوري وتقييم الأداء وتحديث القواعد لمواكبة المشهد المتغير للتهديدات.

1.1.9 الخاتمة

يبقى كشف التسلل مكونًا أساسيًا لبرامج الأمن السيبراني الشاملة، حيث يوفر قدرات حاسمة لتحديد الحوادث الأمنية التي تتجنب الضوابط الوقائية. بينما لا تزال التحديات كبيرة، خاصة فيما يتعلق بالإيجابيات الكاذبة، وتقنيات التهرب، ومتطلبات الموارد، فإن التطورات المستمرة في منهجيات الكشف، والتكامل مع تقنيات الأمن الأخرى، وأفضل الممارسات التشغيلية تستمر في تحسين فعالية الكشف. يمثل التطور من أنظمة كشف معزولة إلى منصات عمليات أمنية متكاملة تقدمًا حاسمًا في معالجة القيود التاريخية. مع استمرار تطور التهديدات السيبرانية في التطور والتصاعدية، يجب أن تتقدم قدرات كشف التسلل بشكل مترابط من خلال البحث المستمر والابتكار والخبرة التنفيذية العملية.

1.2 لمحة شاملة عن الذكاء الاصطناعي

1.2.1 تعريف الذكاء الاصطناعي

الذكاء الاصطناعي (AI) هو مجال في علوم الحاسوب يهدف إلى إنشاء أنظمة قادرة على أداء مهام تتطلب عادةً ذكاءً بشرياً مثل التفكير، الفهم، اتخاذ القرارات، التعلّم من التجارب، حل المشكلات، والإبداع. بخلاف البرمجيات التقليدية، التي تتبع تعليمات مكتوبة مسبقاً، فإن أنظمة الذكاء الاصطناعي تمتلك القدرة على التكيف مع الظروف الجديدة وتحسين أدائها بمرور الوقت من خلال تحليل البيانات والتعلّم منها.

تتضمن تطبيقات الذكاء الاصطناعي العديد من الأمثلة التي نستخدمها يومياً: مساعدات الصوت مثل "سيري" و"أليكسا"، أنظمة التوصية في "نتفلكس" و"أمازون"، أنظمة الترجمة الآلية مثل "جوجل ترانسليت"، وحتى السيارات ذاتية القيادة التي تعتمد على الذكاء الاصطناعي لفهم بيئتها واتخاذ القرارات بشكل لحظي.

من الناحية النظرية، يمكن النظر إلى الذكاء الاصطناعي على أنه محاولة لمحاكاة القدرات الإدراكية البشرية في الآلة، مثل الذاكرة، الإدراك، والتعلم. ومع ذلك، فإن تعريف الذكاء الاصطناعي يتغير باستمرار مع تطور التكنولوجيا، فما كان يُعتبر "ذكاءً اصطناعياً" في الماضي (مثل التعرف على الكتابة على الحاسوب) أصبح اليوم تقنية عادية وبسيطة.

1.2.2 لمحة تاريخية

تاريخ الذكاء الاصطناعي طويل ومعقد، ويمر بعدة محطات مهمة:

• المرحلة النظرية (قبل 1950):

بدأت الفكرة الفلسفية منذ قرون، عندما تساءل الفلاسفة عن إمكانية بناء آلة "تفكر" مثل البشر. كتب الفيلسوف ديكارت وباسكال أفكاراً حول العقل والآلة، لكنها كانت مجرد تصورات فلسفية.

• آلان تورينغ (1950):

اقترح الرياضي البريطاني آلان تورينغ اختباراً ثورياً يُعرف بـ اختبار تورينغ، لقياس ما إذا كان يمكن لآلة أن تُظهر سلوكاً ذكياً غير قابل للتمييز عن الإنسان (Turing, 1950). كما أسس مفهوم آلة تورينغ الذي وضع أساس علوم الحاسوب الحديثة.

• ولادة الذكاء الاصطناعي (1956):

خلال مؤتمر دارتموث بقيادة John McCarthy ، تم استخدام مصطلح “الذكاء الاصطناعي” لأول مرة، ليصبح مجالاً بحثياً رسمياً [23]. ركزت البحوث الأولى على المنطق الرمزي وحل المشكلات الرياضية البسيطة.

• السبعينيات والثمانينيات:

واجه المجال عقبات كبيرة نتيجة قلة القدرة الحاسوبية وضعف البيانات المتوفرة، ما أدى إلى فترة جمود تعرف بـ “شتاء الذكاء الاصطناعي”.

• التسعينيات:

شهدت التسعينيات نجاحات بارزة مثل انتصار حاسوب IBM “ديب بلو” على بطل العالم في الشطرنج جاري كاسباروف عام 1997، مما أثبت أن الآلة يمكن أن تتفوق على الإنسان في مجالات محددة.

• القرن الحادي والعشرون :

بفضل التعلم العميق (Deep Learning) والبيانات الضخمة (Big Data) والقدرات الهائلة للمعالجات الحديثة (GPUs)، عاد الذكاء الاصطناعي بقوة. اليوم نشهد تطبيقات في كل المجالات: الطب، النقل، التمويل، الأمن، التعليم، والترفيه.

1.2.3 أهمية الذكاء الاصطناعي

تكمن أهمية الذكاء الاصطناعي في قدرته على تحويل كافة مجالات الحياة الإنسانية والصناعية. فهو ليس مجرد أداة تقنية، بل قوة محركة لعصر جديد من الابتكار والتغيير. ومن بعض الأمثلة عن أهمية الذكاء الاصطناعي:

1. **في الرعاية الصحية:** يساعد الذكاء الاصطناعي في تحليل صور الأشعة، التنبؤ بالأمراض، وتصميم أدوية جديدة. مثلاً، شركات أدوية مثل DeepMind و Pfizer تستخدم AI لتسريع اكتشاف العلاجات.

2. **في النقل:** السيارات ذاتية القيادة (Tesla, Waymo) قادرة على تقليل الحوادث المرورية، تحسين كفاءة الطرق، وتوفير حلول تنقل للأشخاص ذوي الإعاقة.

3. **في التمويل:** تُستخدم الخوارزميات الذكية للكشف عن الاحتيال، أتمتة التداول، وتحليل المخاطر بدقة أعلى من البشر.

4. **في التعليم:** يمكن للذكاء الاصطناعي توفير تعليم شخصي للطلاب من خلال أنظمة ذكية تكشف نقاط ضعفهم وتقترح خطط تعلم فردية.

5. **في الصناعة:** الروبوتات الذكية تؤدي مهاماً شاقة أو خطيرة، وتساهم أنظمة التنبؤ بالصيانة في توفير مليارات الدولارات عبر منع الأعطال قبل وقوعها.

6. **في الحياة اليومية:** من استخدام المساعدات الرقمية إلى الترجمة الفورية وتخصيص المحتوى على الإنترنت، أصبح الذكاء الاصطناعي جزءاً لا يتجزأ من حياتنا.

بعبارة أخرى، أهمية الذكاء الاصطناعي تكمن في كونه أداة لتسريع التقدم البشري، زيادة الإنتاجية، ودفع عجلة الابتكار، لكنه في الوقت ذاته يفرض تحديات أخلاقية واجتماعية يجب التعامل معها بحذر.

1.2.4 أنواع الذكاء الاصطناعي

الذكاء الاصطناعي (AI) هو مفهوم واسع يشمل مجموعة من الأنظمة التي تسعى لمحاكاة القدرات البشرية، ولكنه يختلف من حيث القدرات التي يمتلكها. يمكن تصنيف الذكاء الاصطناعي إلى ثلاثة أنواع رئيسية حسب مستوى تعقيد النظام وقدرته على محاكاة الذكاء البشري: الذكاء الاصطناعي الضعيف، الذكاء الاصطناعي القوي، والذكاء الاصطناعي الفائق.

1- الذكاء الاصطناعي الضعيف (Narrow AI)

الذكاء الاصطناعي الضعيف هو النوع الأكثر شيوعًا واستخدامًا في حياتنا اليومية. هذا النوع من الذكاء الاصطناعي مُصمم للقيام بمهام محددة للغاية، ولا يمتلك القدرة على أداء مهام خارج نطاق ما تم تدريبه عليه. ومن أبرز أمثله المساعدات الصوتية مثل Siri و Alexa و Google Assistant، التي تتمتع بقدرة على فهم اللغة المنطوقة وإتمام مهام بسيطة مثل تحديد مواعيد أو تشغيل موسيقى. كما يشمل الذكاء الاصطناعي الضعيف تطبيقات أخرى مثل التعرف على الصور، حيث يمكن للأنظمة التعرف على الأشكال والوجوه بدقة عالية، وأنظمة التوصية التي تقدم اقتراحات للمستخدم بناءً على تفضيلاته، مثل تلك التي تستخدمها منصات مثل Netflix و Amazon لتوجيه المستخدمين إلى المحتوى الذي قد يروق له في هذه الحالة [24]، يقوم الذكاء الاصطناعي بأداء مهمة واحدة بشكل متميز وفعال، لكنه يظل محدودًا في نطاقه.

2- الذكاء الاصطناعي القوي (AGI)

الذكاء الاصطناعي القوي (Artificial General Intelligence) هو النوع الذي يسعى إلى محاكاة الذكاء البشري بشكل كامل، بحيث تكون الأنظمة قادرة على أداء أي مهمة إدراكية يقوم بها الإنسان. على عكس الذكاء الاصطناعي الضعيف، الذي يقتصر على مهام محددة، يمكن للذكاء الاصطناعي القوي أن يتعلم وينفذ مهام جديدة تمامًا، تمامًا كما يفعل البشر. ورغم أن هذا المفهوم لا يزال نظريًا إلى حد بعيد، إلا أنه إذا تحقق، فإنه سيحدث ثورة في مجالات متعددة مثل العلم والطب والهندسة، حيث يمكن للأنظمة الذكية القوية حل المشكلات المعقدة بسرعة تفوق قدرة الإنسان. هذا النوع من الذكاء الاصطناعي قد يعيد تشكيل الطريقة التي

نعيش بها، من خلال تمكين الأنظمة من التفكير المستقل واتخاذ القرارات بمستوى عالٍ من المرونة والقدرة على التعلم [25].

3- الذكاء الاصطناعي الفائق (Superintelligence)

الذكاء الاصطناعي الفائق يشير إلى نوع من الأنظمة التي تفوق الذكاء البشري في جميع جوانب القدرة العقلية. في هذا المستوى، يمكن للذكاء الاصطناعي أن يتفوق في المجالات كافة، من الإبداع إلى حل المشكلات، ومن الذكاء الاجتماعي إلى الفهم العاطفي. يعتقد البعض أن الذكاء الاصطناعي الفائق قد يمثل الحلول الكبرى لمشاكل العالم مثل الفقر والأمراض، من خلال القدرة على التفكير بشكل أسرع وأكثر دقة من الإنسان. ومع ذلك، يطرح البعض الآخر مخاوف جدية حول مخاطره الوجودية، حيث قد يكون من الصعب أو حتى من المستحيل التحكم في الأنظمة التي تتفوق في ذكائها على البشر [26]. هذه المخاوف تشمل القلق من أن تتطور هذه الأنظمة إلى قوة مهيمنة قد تخرج عن السيطرة وتؤثر على مستقبل الإنسانية بشكل غير متوقع.

1.2.5 المكونات الأساسية للذكاء الاصطناعي

لكي تعمل أنظمة الذكاء الاصطناعي بكفاءة، تحتاج إلى عدة مكونات رئيسية: التعلم الآلي، معالجة اللغة الطبيعية، الرؤية الحاسوبية، والروبوتات.

1- التعلم الآلي (Machine Learning): يعد التعلم الآلي أحد الفروع الأساسية للذكاء الاصطناعي. في هذا المجال، تتعلم الخوارزميات من البيانات بدلاً من أن تكون مبرمجة يدوياً للقيام بمهمة معينة. يتضمن التعلم الآلي عدة أنواع، أبرزها:

- **التعلم تحت الإشراف (Supervised Learning):** يعتمد على وجود مجموعة بيانات تحتوي على أمثلة مدروسة مع الإجابات الصحيحة، حيث تتعلم الخوارزمية كيفية التنبؤ بالإجابات بناءً على هذه الأمثلة.


• **التعلم غير المراقب (Unsupervised Learning):** لا يتطلب وجود إجابات صحيحة، حيث تعمل الخوارزميات على اكتشاف الأنماط أو الهياكل الخفية داخل البيانات.

• **التعلم المعزز (Reinforcement Learning):** يعتمد على مكافآت وعقوبات لتوجيه الخوارزمية لأداء المهام بطريقة تزيد من المكافآت بمرور الوقت .

2- **معالجة اللغة الطبيعية (NLP):** تمكّن الآلات من فهم اللغة البشرية، وتُستخدم في المساعدات الصوتية، الترجمة الآلية (Google Translate)، وروبوتات المحادثة [27].

3- **الرؤية الحاسوبية (Computer Vision):** تركز على تمكين الآلات من فهم الصور والفيديوهات. تطبيقاتها تشمل: التعرف على الوجوه، السيارات ذاتية القيادة، وتشخيص الصور الطبية [28].

4- **الروبوتات (Robotics):** تجمع بين الذكاء الاصطناعي والأنظمة الفيزيائية لأداء مهام مستقلة. تشمل: الأتمتة الصناعية، الروبوتات الجراحية، وروبوتات الاستكشاف في الفضاء وأعماق البحار.



1.2 مكونات الذكاء الاصطناعي

1.2.6 الذكاء الاصطناعي في التطبيقات الواقعية

قد أصبح الذكاء الاصطناعي (AI) جزءاً لا يتجزأ من التطور التكنولوجي السريع الذي نشهده في عالمنا اليوم. فقد أثر بشكل عميق في عدة صناعات، وجلب معه فرصاً جديدة للتطور والإبداع. في حين يعزز الذكاء الاصطناعي من كفاءة الأعمال ويسهم في الأتمتة، فإنه أيضاً يفتح أبواباً لمجالات جديدة لم تكن لتتخيلها العقول البشرية قبل عقدين من الزمن. وبالنظر إلى المجالات الرئيسية التي استفادت من الذكاء الاصطناعي، يمكننا رؤية تباين كبير في تطبيقاته.

-النقل-

في مجال النقل، قاد الذكاء الاصطناعي ثورة في السيارات ذاتية القيادة، وهو ما يعد خطوة جريئة نحو الحد من الحوادث المرورية وتحسين كفاءة النقل. تسهم خوارزميات الذكاء الاصطناعي في إدارة حركة المرور في المدن الذكية، مما يساهم في تقليل الازدحام وتحسين انسيابية التنقل في المناطق الحضرية. بالإضافة إلى ذلك، يعزز الذكاء الاصطناعي من فعالية سلاسل التوريد، من خلال تحسين التنبؤات وتقليل التكاليف في النقل والخدمات اللوجستية [30].

-البيع بالتجزئة والتجارة الإلكترونية:-

أما في مجال التجارة الإلكترونية والبيع بالتجزئة، فقد شهدنا تحولات كبيرة بفعل الذكاء الاصطناعي، حيث أصبحت أنظمة التوصية جزءاً أساسياً من تجربة المستخدم. تقوم خوارزميات الذكاء الاصطناعي بتحليل سلوك المستهلك وتقديم توصيات مخصصة، مما يعزز من تجربة الشراء [31]. علاوة على ذلك، يتم تحسين إدارة المخزون والخدمات اللوجستية، ما يساعد المتاجر الإلكترونية على تقديم خدمة أفضل للعملاء.

1.2.7 الآثار الأخلاقية والاجتماعية للذكاء الاصطناعي

رغم هذه الفوائد الكبيرة، لا يمكن تجاهل الآثار الأخلاقية والاجتماعية التي قد تترتب على استخدام الذكاء الاصطناعي. إن استغلال هذه التقنية يحتاج إلى مراجعة دقيقة لتداعياتها على المجتمع والفرد.

-فقدان الوظائف

من أبرز التحديات التي يثيرها الذكاء الاصطناعي هو تأثيره على سوق العمل. مع تقدم الأتمتة، قد يُستبدل عدد كبير من الوظائف التقليدية بالأنظمة الذكية، ما يؤدي إلى بطالة واسعة في بعض القطاعات [32]. ولتقليل هذه المخاطر، يتعين على الحكومات والشركات الاستثمار في برامج إعادة تأهيل العمال وتطوير مهاراتهم لتمكينهم من التعامل مع التغيرات التكنولوجية.

-التحيز والتمييز

من القضايا الأخرى التي يثيرها الذكاء الاصطناعي هي مسألة التحيز في البيانات. إذا تم تدريب أنظمة الذكاء الاصطناعي على مجموعات بيانات متحيزة، فإن ذلك قد يؤدي إلى نتائج غير عادلة تعزز الفوارق الاجتماعية والاقتصادية [33]. لمعالجة هذه المشكلة، هناك حاجة إلى تطوير خوارزميات أكثر عدلاً واعتماد ممارسات بيانات متنوعة تتجنب هذه التحيزات.

-قضايا الخصوصية

لخصوصية هي إحدى القضايا البارزة التي تثيرها تطبيقات الذكاء الاصطناعي، خاصة في مجالات مثل المراقبة والتعرف على الوجوه. إن تكاثر البيانات الشخصية والمعاملات الرقمية يجعل من الصعب ضمان حماية الخصوصية [34]. وبالتالي، تبرز الحاجة إلى وضع قوانين أكثر صرامة لحماية هذه البيانات وضمان استخدامها في إطار قانوني وآمن.

-حوكمة الذكاء الاصطناعي

بناءً على ما سبق، تبرز الحاجة إلى تطوير إطار تنظيمي قوي للذكاء الاصطناعي، يضمن الشفافية والمساءلة والعدالة في استخدام هذه التقنية . وقد تبنت العديد من الدول والمنظمات الدولية مثل الاتحاد الأوروبي ومنظمة التعاون الاقتصادي والتنمية هذا التوجه لضمان أن تكون تطبيقات الذكاء الاصطناعي آمنة ومسؤولة.

1.2.8 الآفاق المستقبلية في الذكاء الاصطناعي

من المرجح أن يتوسع الذكاء الاصطناعي في مجالات أكثر تقدماً، مما يجلب فرصاً ومخاطر جديدة. من بعض هذه التوسعات:

تعزيز القدرات البشرية: تشمل التطبيقات الأطراف الصناعية المدعومة بالذكاء الاصطناعي وأدوات تعزيز القدرات الإدراكية [35].

الذكاء الاصطناعي العام (AGI): يهدف الذكاء الاصطناعي العام إلى بلوغ مستوى الذكاء البشري. ورغم إمكاناته الهائلة، إلا أنه يثير مخاوف تتعلق بالسلامة وضبط الأهداف.

التفرد التكنولوجي: توقع Kurzweil (2005) [36]. أن النمو الأسّي للذكاء الاصطناعي قد يؤدي إلى تفرد تكنولوجي يغيّر المجتمع جذرياً

1.2.9 الخاتمة

لقد غيّر الذكاء الاصطناعي مجرى التاريخ في العديد من المجالات. ورغم ما يقدمه من فوائد هائلة في الابتكار وحل المشاكل، إلا أنه يثير تحديات أخلاقية واجتماعية قد تؤثر على حياتنا اليومية. لضمان استخدام هذه التكنولوجيا بشكل مسؤول، لابد من تطوير سياسات وقوانين متوازنة تساعد على استثمار إمكانات الذكاء الاصطناعي مع الحفاظ على القيم الإنسانية وحماية المجتمع.

1.3 لمحة شاملة عن SIEM

1.3.1 تعريف ونطاق SIEM

أنظمة إدارة معلومات وأحداث الأمن (SIEM) هي جانب حيوي من استراتيجيات الأمن السيبراني الحديثة، حيث توفر منصة مركزية لجمع وتحليل والتصرف في مجموعة واسعة من البيانات المتعلقة بالأمن. تم تصميم حلول SIEM لتقديم نظرة شاملة ورؤى دقيقة حول وضع الأمن في المنظمة، مما يمكن من الاكتشاف السريع والاستجابة للتهديدات المحتملة.

يشمل تعريف SIEM عنصرين رئيسيين: إدارة معلومات الأمان (SIM) وإدارة أحداث الأمان (SEM). تشمل إدارة معلومات الأمان جمع وتخزين وتحليل بيانات الأمان من مصادر مختلفة ضمن بيئة تكنولوجيا المعلومات. قد تشمل هذه البيانات سجلات النظام، وبيانات حركة المرور على الشبكة، وغيرها من الأدلة الرقمية ذات الصلة. الهدف الرئيسي هنا هو جمع أكبر قدر ممكن من المعلومات ذات الصلة لدعم فهم جيد للحوادث الأمنية وضمان الاحتفاظ بالبيانات على المدى الطويل من أجل التحليل الجنائي .

من ناحية أخرى، تركز إدارة أحداث الأمان على المراقبة في الوقت الفعلي، والربط، والتنبيه حول الأحداث الأمنية. وهي مسؤولة عن تحديد الأنماط التي تشير إلى الحوادث الأمنية المحتملة من خلال تحليل تدفقات البيانات والأحداث أثناء حدوثها. يستخدم SEM خوارزميات متقدمة وقواعد معرفة للكشف عن الأنماط غير الطبيعية والأنشطة المشبوهة والتهديدات المحتملة. يضمن الجمع بين SIM و SEM أن منصة SIEM لا تقتصر فقط على جمع وتخزين البيانات الأساسية، بل توفر أيضًا معلومات قابلة للعمل لفرق الأمان.

لقد تطور نطاق SIEM بشكل كبير مع تزايد تعقيد التهديدات السيبرانية. في البداية، كانت حلول SIEM تعتمد بشكل رئيسي من قبل الشركات الكبيرة ذات البنى التحتية الواسعة لتكنولوجيا المعلومات. ومع ذلك، فإن تزايد وتيرة وشدة الهجمات السيبرانية قد دفع المنظمات من جميع الأحجام إلى تنفيذ أنظمة SIEM. يتجاوز نطاق SIEM الحديث إدارة السجلات فقط ويشمل عدة وظائف حاسمة:

1. **جمع وإدارة السجلات:** تقوم أنظمة SIEM بجمع البيانات من مجموعة متنوعة من المصادر، بما في ذلك الخوادم، والجدران النارية، والموجهات، والتطبيقات، ونقاط النهاية. تسهل هذه المنصة المركزية جمع السجلات وإدارة وتحليل البيانات بشكل موحد، مما يوفر رؤية شاملة لمشهد الأمان في المنظمة.

2. **المراقبة والتنبيه في الوقت الفعلي:** من خلال تحليل البيانات الواردة بشكل مستمر، يمكن لأنظمة SIEM تقديم تنبيهات في الوقت الفعلي حول الأحداث الأمنية المحتملة. وهذا يمكن فرق الأمان من الرد بسرعة على التهديدات المحتملة، مما يقلل من فترة تعرض المنظمة للثغرات.

3. **كشف الحوادث والاستجابة لها:** تقدم أنظمة SIEM أيضًا القدرة على تحديد الحوادث الأمنية المحتملة من خلال قواعد الارتباط المتقدمة والخوارزميات السلوكية.

بمجرد اكتشاف التهديد، يمكن لمنصات SIEM أن تبدأ تلقائيًا تنفيذ بروتوكولات الاستجابة المحددة مسبقًا، مثل عزل الأنظمة المتأثرة أو تفعيل تدفقات استجابة الحوادث.

4. **التقارير الخاصة بالامتثال:** العديد من الصناعات تخضع لمتطلبات تنظيمية تفرض الاحتفاظ وتحليل بيانات الأمان. غالبًا ما تأتي حلول SIEM مع قدرات تقارير الامتثال المدمجة، مما يساعد المنظمات على الوفاء بالمعايير التشريعية والمعايير الخاصة بالصناعة مثل GDPR و HIPAA و PCI-DSS.

5. **تكامل معلومات التهديدات:** يمكن للحلول الحديثة لـ SIEM أن تتكامل مع موجزات معلومات التهديدات لإثراء البيانات السياقية المتاحة للتحليل. وهذا يمكن المنظمات من البقاء في صدارة التهديدات الناشئة من خلال الاستفادة من المعلومات في الوقت الفعلي حول الثغرات المعروفة، وطرق الهجوم، وسلوكيات المعتدين.

6. **التحليل الجنائي:** في أعقاب حادث أمني، توفر أنظمة SIEM بيانات ثمينة للتحقيقات الجنائية. يمكن تحليل البيانات التاريخية المخزنة في منصة SIEM لتتبع تسلسل الزمان لهجوم، وتحديد نقاط الدخول، وفهم نطاق الاختراق.

إحدى النقاط القوية لـ SIEM تكمن في قدرته على تقديم رؤية شاملة للوضع الأمني للمنظمة، من خلال دمج البيانات من مصادر متفرقة لتكشف سرًا متماسكًا لأحداث الأمان. ومع ذلك، فإن تنفيذ وتشغيل نظام SIEM يقدمان بعض التحديات. تشمل هذه التحديات الحجم الكبير للبيانات التي يجب إدارتها، وتعقيد قواعد الارتباط والخوارزميات، والحاجة إلى ضبط مستمر لتجنب الإيجابيات الكاذبة والسلبيات الكاذبة.

في الختام، فإن تعريف ونطاق SIEM يجسد نهجًا شاملاً نحو الأمن السيبراني، يهدف إلى تعزيز قدرة المنظمة على اكتشاف التهديدات والرد عليها والتخفيف من آثارها. من خلال دمج جمع البيانات مع التحليل المتقدم وقدرات التنبيه، تشكل أنظمة SIEM مكونًا محوريًا في استراتيجية فعالة للأمن السيبراني، مما يحمي الأصول التنظيمية في ظل بيئة رقمية أصبحت أكثر خطورة.

1.3.2 دور SIEM في ضمان الأمان

أصبحت أنظمة SIEM مركزية في استراتيجيات الأمن السيبراني الحديثة، حيث تلعب دورًا محوريًا في تحديد التهديدات والرد عليها والتخفيف منها. تقوم هذه الأنظمة بجمع وتحليل البيانات من مصادر متعددة ضمن البنية التحتية لتكنولوجيا المعلومات للمنظمة، مما يخلق رؤية شاملة لمشهد الأمان. من خلال القيام بذلك، تمكن أدوات SIEM المنظمات من اكتشاف الحوادث الأمنية في الوقت الفعلي، مما يوفر أداة لا تقدر بثمن للحفاظ على أوضاع أمان قوية.

أحد الوظائف الرئيسية لـ SIEM هو جمع وتوحيد البيانات من مصادر متفرقة مثل الجدران النارية، أنظمة الكشف عن التسلل/أنظمة منع التسلل (IDS/IPS)، الخوادم، التطبيقات، وغير ذلك. يضمن هذا الجمع أن تكون جميع البيانات ذات الصلة متمركزة، مما يعزز منصة التحليل الموحدة. من خلال التوحيد، تستطيع أنظمة SIEM جمع البيانات في شكل مشترك، مما يسهل تحليلها وارتباطها من مصادر متعددة. وهذا أمر بالغ الأهمية لأنه يحول البيانات الخام إلى معلومات قابلة للعمل، مما يساهم في اتخاذ قرارات سريعة ومدروسة.

المراقبة في الوقت الفعلي هي قدرة أساسية أخرى لـ SIEM. مع تزايد تعقيد التهديدات السيبرانية، أصبحت القدرة على مراقبة الأنظمة بشكل مستمر وفي الوقت الفعلي أمراً بالغ الأهمية. تستخدم أنظمة SIEM قواعد الارتباط والتحليلات المتقدمة لاكتشاف الأنماط الشاذة والأنشطة الخبيثة المحتملة عبر الشبكة. على سبيل المثال، إذا تم اكتشاف محاولة تسجيل دخول لمستخدم من مواقع جغرافية متعددة خلال فترة زمنية قصيرة، يمكن لنظام SIEM تحديد هذا السلوك كأمر مشبوه وتحفيز تنبيه. من خلال ربط البيانات من مصادر متعددة، يمكن لأنظمة SIEM تحديد أحداث قد تشير إلى اختراق أمني، حتى إذا كان كل حدث على حدة يبدو غير ضار.

بمجرد تحديد التهديد المحتمل، تلعب أنظمة SIEM دوراً حيوياً في استجابة الحوادث. حيث توفر تفاصيل دقيقة حول طبيعة التهديد، والنظام المتأثر، والجدول الزمني للأحداث، والتي تعد جميعها أمراً حاسماً من أجل الإصلاح الفعال. بالإضافة إلى ذلك، توفر حلول SIEM إمكانيات استجابة آلية، مثل عزل الأنظمة المتأثرة أو حظر عناوين IP الخبيثة، مما يقلل من تأثير التهديدات مع الحد الأدنى من التأخير. تساعد هذه الأتمتة المنظمات على الاستجابة بسرعة للتهديدات، مما يقلل من فرص المهاجمين.

التوافق مع اللوائح هو أمر آخر حيث تكون أنظمة SIEM ضرورية. تفرض اللوائح مثل GDPR و HIPAA و PCI-DSS على المنظمات الحفاظ على سجلات مفصلة للبيانات الأمنية وضمان نزاهة وسرية المعلومات الحساسة. تساعد أنظمة SIEM المنظمات على تلبية المتطلبات التنظيمية من خلال توفير قدرات جمع بيانات قوية وتوليد تقارير تدقيق شاملة. إن القدرة على إنتاج تقارير موثوقة وتوثيق التدابير الأمنية يضمن أن المنظمات قادرة على إثبات امتثالها للأنظمة، وبالتالي تجنب الغرامات القانونية والتبعات المالية.

بالإضافة إلى اكتشاف التهديدات والامتثال، تساهم أنظمة SIEM في الاستراتيجية الأمنية العامة من خلال التحسين المستمر والتطوير. من خلال تحليل البيانات التاريخية، تمكن هذه الأنظمة المنظمات من تحديد المشكلات المتكررة، وتقييم فعالية تدابير الأمان الحالية، واتخاذ قرارات مستنيرة بشأن الاستثمارات المستقبلية

في البنية التحتية للأمان. يضمن هذا النهج الاستباقي أن المنظمات لا تقتصر على التفاعل مع الحوادث فقط، بل تعمل على تعزيز موقف الأمان لديها بشكل مستمر.

علاوة على ذلك، مع اعتماد المنظمات بشكل متزايد على خدمات السحابة والتقنيات المحمولة، يصبح مشهد الأمان أكثر تعقيدًا وديناميكية. تتطور أنظمة SIEM لمواجهة هذه التحديات من خلال دمج ميزات متقدمة مثل التعلم الآلي، وتحليل سلوك المستخدم والأنشطة (UEBA)، ودمج معلومات التهديدات. تعزز هذه الابتكارات قدرة أنظمة SIEM على اكتشاف التهديدات المعقدة والتكيف مع بيئة الأمان المتغيرة باستمرار.

أحد الاتجاهات الناشئة في مشهد SIEM هو تكامل SIEM مع منصات تنسيق الأمان والأتمتة والاستجابة (SOAR). يعزز هذا التكامل قدرات SIEM من خلال إضافة سير العمل الآلي وكتب التشغيل الخاصة بالاستجابة للحوادث، مما يقلل من وقت الاستجابة ويحسن كفاءة العمليات الأمنية.

باختصار، تلعب أنظمة SIEM دورًا حيويًا في نجاح استراتيجية الأمان في المنظمة. من خلال توفير المراقبة في الوقت الفعلي، والاستجابة للحوادث، ودعم الامتثال، والتحسين المستمر، تمكن أدوات SIEM المنظمات من اكتشاف التهديدات والرد عليها والتخفيف من أثارها بشكل فعال. مع تطور مشهد الأمان السيبراني، ستتطور أيضًا قدرات أنظمة SIEM، مما يضمن بقاؤها جزءًا لا غنى عنه من استراتيجية الأمان الشاملة.

1.3.3 نظرة تاريخية حول أنظمة SIEM

لقد تطورت أنظمة SIEM بشكل كبير منذ نشأتها، مما يعكس التغيرات الأوسع في مشهد الأمن السيبراني وتكنولوجيا المعلومات. لفهم الجوانب التاريخية لأنظمة SIEM، من الضروري التعمق في أصولها وتطورها والعوامل التي دفعت إلى تبنيها وتطورها.

يمكن إرجاع نشأة SIEM إلى أواخر التسعينيات وبداية العقد الأول من الألفية الجديدة. في تلك الفترة، بدأت المؤسسات في إدراك أهمية جمع وتحليل البيانات المتعلقة بالأمن من مصادر مختلفة داخل شبكاتها. الأدوات الأمنية المبكرة مثل أنظمة كشف التسلل (IDS) وأنظمة إدارة السجلات قدمت رؤية حول التهديدات الأمنية المحتملة وانتهاكات السياسات. ومع ذلك، كانت هذه الأدوات غالبًا معزولة وتفتقر إلى القدرة على ربط البيانات من مصادر مختلفة، مما أدى إلى رؤى مجزأة وغير مكتملة عن الوضع الأمني للمؤسسة.

إن التعقيد المتزايد لبيئات تكنولوجيا المعلومات وتطور الهجمات الإلكترونية تطلب نهجًا أكثر شمولاً لمراقبة وإدارة الأمن. أدى ذلك إلى ظهور مفهوم SIEM، وهو مصطلح يجمع بين إدارة معلومات الأمن (SIM) وإدارة أحداث الأمن (SEM). تركز SIM على جمع وتخزين وتحليل البيانات المتعلقة بالأمن، بينما تركز SEM على المراقبة اللحظية وربط الأحداث الأمنية. من خلال دمج هاتين الوظيفتين، قدمت أنظمة SIEM حلاً موحدًا لإدارة وتحليل المعلومات الأمنية.

الحلول المبكرة لـ SIEM مثل تلك التي طورتها شركات مثل ArcSight (تأسست عام 2000) وNetForensics استُخدمت بشكل أساسي من قبل المؤسسات الكبيرة والوكالات الحكومية. امتلكت هذه المنظمات الموارد والخبرة اللازمة لتنفيذ وإدارة البنى التحتية المعقدة التي تتطلبها تلك الأنظمة. كانت الاستخدامات الرئيسية لأنظمة SIEM في تلك المرحلة تشمل: إعداد تقارير الامتثال، كشف التهديدات، والاستجابة للحوادث. كما دفعت المتطلبات التنظيمية، مثل قانون ساربنز أوكسلي (SOX) لعام 2002 وقانون HIPAA لعام 1996، العديد من المؤسسات إلى اعتماد أنظمة SIEM للوفاء بالتزاماتها التنظيمية.

ومع نضوج التكنولوجيا، بدأت أنظمة SIEM تتبنى ميزات أكثر تقدمًا، مثل التنبيهات اللحظية، وأتمتة الاستجابة للحوادث، ودعم نطاق أوسع من مصادر البيانات. كما ساهم ظهور تقنيات البيانات الضخمة والاستخدام المتزايد للتعليم الآلي (ML) والذكاء الاصطناعي (AI) في تعزيز قدرات هذه الأنظمة. مكّنت هذه التطورات المؤسسات من التعامل مع كميات أكبر من البيانات، وكشف تهديدات أكثر تعقيدًا، وتقليل الوقت المطلوب لتحديد والاستجابة للحوادث الأمنية.

شهد منتصف العقد الثاني من الألفية نقطة تحول مهمة في تبني أنظمة SIEM، حيث أكدت الهجمات السيبرانية وتسريبات البيانات على الحاجة إلى حلول أمنية قوية.

لقد أبرزت الحوادث البارزة مثل اختراق Target في عام 2013 وقرصنة Sony Pictures في عام 2014 العواقب الخطيرة لضعف المراقبة الأمنية، وسرّعت من اعتماد أنظمة SIEM في مختلف الصناعات. خلال هذه الفترة، وسّع مزودو SIEM عروضهم لتشمل حلولاً قائمة على السحابة وخدمات مُدارة، مما جعل التكنولوجيا أكثر سهولة للشركات الصغيرة والمتوسطة (SMEs) التي لم تكن تمتلك الموارد اللازمة لإدارة أنظمة SIEM محلياً.

تستمر أنظمة SIEM الحديثة في التطور استجابةً للتحديات الجديدة في الأمن السيبراني والتطورات التكنولوجية. إن التّبنى المتزايد للحوسبة السحابية، وأجهزة إنترنت الأشياء (IoT)، وبيئات العمل عن بُعد، قد وسّع من مساحة الهجوم وأدخل تعقيدات جديدة لمراقبة الأمن.

تم تصميم حلول SIEM المعاصرة للتعامل مع هذه التحديات من خلال توفير رؤية محسّنة ووعياً سياقياً عبر البيانات السحابية الهجينة والمتعددة. كما تستفيد من التحليلات المتقدمة، والتحليل السلوكي، وتغذية معلومات التهديدات من أجل تحسين دقة وكفاءة كشف التهديدات والاستجابة لها.

1.3.4 المفاهيم الأساسية في أنظمة SIEM

تعد أنظمة إدارة معلومات وأحداث الأمن (SIEM) مكوناً أساسياً في مجال الأمن السيبراني، حيث صُممت لتوفير تحليل لحظي للتنبيهات الأمنية الناتجة عن التطبيقات، وأجهزة الشبكات، والبنية التحتية الأخرى لتقنية المعلومات. تأتي مرونة أنظمة SIEM من مجموعة من المفاهيم الأساسية التي تُنشئ معاً إطاراً قوياً لتحديد الحوادث الأمنية وتحليلها والاستجابة لها. تتناول هذه الفقرة أبرز هذه المفاهيم: ترابط الأحداث، إدارة السجلات، المراقبة اللحظية، الاستجابة للحوادث، وإعداد تقارير الامتثال.

يعد ترابط الأحداث وظيفية جوهرية في أنظمة SIEM. جوهر هذه العملية يتمثل في تجميع كميات ضخمة من البيانات من مصادر متباينة وتحليلها لاستخلاص المعنى. الأحداث التي قد تبدو عادية عند النظر

إليها بشكل منفصل يمكن أن تُظهر نمطًا مقلًا عند ربطها معًا. على سبيل المثال: محاولات تسجيل دخول فاشلة متعددة تليها محاولة ناجحة قد تُشير إلى هجوم (Brute Force Attack). تستخدم أدوات SIEM خوارزميات وقواعد معدة مسبقًا لربط هذه الأحداث في الزمن الحقيقي، مما يمكن محلي الأمن من اكتشاف الحوادث والتحقيق فيها التي قد تفوتها المراقبة التقليدية.

تشير إدارة السجلات إلى العملية الآلية لجمع وتخزين وإدارة بيانات السجلات الناتجة عن أجهزة الشبكة، والخوادم، والتطبيقات، وأنظمة تقنية المعلومات الأخرى. تُركز حلول SIEM هذه البيانات في مكان واحد، مما يضمن الاحتفاظ طويل الأجل بها في صيغة آمنة وغير قابلة للتغيير. تساعد إدارة السجلات الفعالة ليس فقط في الامتثال والتحليل الجنائي، بل تعزز أيضًا من كفاءة عمليات كشف التهديدات ومعالجتها. كما أن تحليل وتطبيع بيانات السجلات من مصادر مختلفة يمكن أنظمة SIEM من إنشاء قاعدة بيانات موحدة وقابلة للبحث بسهولة.

المراقبة اللحظية هي قدرة أنظمة SIEM على مراقبة حركة مرور الشبكة، وأنشطة المستخدمين، وسلوكيات الأنظمة بشكل مستمر لاكتشاف الأنشطة المشبوهة أو الخبيثة. تُعد هذه القدرة ضرورية لتحديد التهديدات المحتملة فور وقوعها، مما يتيح استجابات أسرع تقلل من الأضرار المحتملة. توفر لوحات التحكم (Dashboards) تصورات وتنبيهات تُبرز الشذوذات، بينما تستخدم التحليلات المتقدمة تقنيات التعلم الآلي لاكتشاف مؤشرات خفية للاختراق. إن الفورية في المراقبة اللحظية تضمن أن تتمكن المؤسسات من الاستجابة بسرعة للتهديدات الأمنية المتطورة.

تشمل الاستجابة للحوادث ضمن إطار عمل SIEM الاستراتيجيات والعمليات اللازمة للتعامل مع التهديدات الأمنية والتخفيف من أثارها بشكل فعال. غالبًا ما تتكامل منصات SIEM مع أنظمة تذاكر الدعم (Ticketing Systems)، لتنسيق استجابة منظمة من خلال التنبيهات الآلية، وسير عمل التحقيقات، وخطط الاستجابة المحددة مسبقًا. عندما يحدد النظام حادثًا آمنًا، يمكن لفرق الأمن بسرعة تقييم خطورته، وتحديد الأنظمة المتأثرة، وتنفيذ التدابير المضادة. تلعب الأتمتة دورًا محوريًا هنا، حيث يمكنها تنفيذ

استجابات معدة مسبقًا مثل عزل الأجهزة المتأثرة أو تفعيل تحديثات لسياسات الأمان. هذا النهج المنظم يقلل من وقت التوقف وفقدان البيانات.

أحد الجوانب المحورية في نشر حل SIEM هو قدرته على تسهيل الامتثال للمعايير التنظيمية مثل GDPR، وHIPAA، وPCI DSS. تتطلب هذه اللوائح تسجيلًا ومراقبة وإعداد تقارير واسعة النطاق حول الأحداث الأمنية. تُبسّط أدوات SIEM عملية الامتثال من خلال إنشاء تقارير شاملة آليًا تلبي المتطلبات التنظيمية المحددة. كما توفر أيضًا مسارات تدقيق ورؤى حول انتهاكات السياسات، مما يعزز الشفافية والمساءلة. إن المراقبة المستمرة للامتثال تساعد المؤسسات على تجنب العقوبات وإظهار التزامها بحماية البيانات.

1.3.5 مكونات نظام SIEM الفعال

تُعد أنظمة إدارة معلومات وأحداث الأمان (SIEM) جزءًا أساسيًا من استراتيجيات الأمن السيبراني الحديثة. تعتمد المؤسسات على حلول SIEM من أجل جمع وتحليل البيانات الأمنية من مصادر متعددة، مما يوفر رؤية شاملة ويُمكن من الكشف الاستباقي عن التهديدات. تتكون أنظمة SIEM الفعالة من عدة مكونات رئيسية، يلعب كل منها دورًا حاسمًا في ضمان المراقبة الأمنية القوية والاستجابة للحوادث.

جمع البيانات و توحيدها: الركيزة الأساسية لأي نشر فعال لـ SIEM هي قدرته على جمع وتوحيد البيانات من مجموعة واسعة من المصادر. تشمل هذه المصادر أجهزة الشبكة، الخوادم، التطبيقات، الأجهزة الأمنية (مثل الجدران النارية وأنظمة كشف/منع التسلل) ، و منصات حماية نقاط النهاية. إن البيانات المجمعة توفر رؤية شاملة لوضع الأمن في المؤسسة وتُعد بمثابة مادة خام للتحليلات اللاحقة.

إدارة السجلات: تُعد السجلات المصدر الأساسي للبيانات التي تعمل عليها أنظمة SIEM. يجب أن تمتلك الأنظمة الفعالة قدرات قوية لإدارة السجلات، بما في ذلك: جمع السجلات، تخزينها، و صيانتها بشكل يضمن أنها غير قابلة للتغيير ومتاحة لفترات طويلة، كما تتطلب اللوائح التنظيمية. يُعد ضمان سلامة

وتوافر السجلات أمرًا بالغ الأهمية سواء للتحليل الجنائي أو للامتثال لمتطلبات تنظيمية مثل: GDPR، PCI-DSS ،HIPAA.

المراقبة اللحظية والتنبيهات: تُعد المراقبة اللحظية المستمرة وظيفة حيوية لأنظمة SIEM. تمكن هذه القدرة من مراقبة حركة مرور الشبكة والأحداث داخل الأنظمة بشكل لحظي، مما يسمح للمؤسسات بالكشف عن الحوادث الأمنية والاستجابة لها فور وقوعها. ينبغي على أنظمة SIEM الفعالة أن تولّد تنبيهات استنادًا إلى قواعد معدة مسبقًا وشذوذات تُشير إلى تهديدات أمنية محتملة. ويجب أن تكون هذه التنبيهات مصنّفة بدقة لتفريق الضوضاء العادية في الشبكة عن القضايا الأمنية الحقيقية، مما يقلل من الإنذارات الكاذبة ويضمن قدرة فرق الأمن على الاستجابة بسرعة للحوادث الحرجة.

محرك الترابط: من المكونات الأساسية لحلول SIEM الفعالة قدرتها على ترابط البيانات من مصادر مختلفة للتعرف على الأنماط والعلاقات التي قد لا تُشير بشكل منفرد إلى تهديد أمني. يقوم محرك الترابط بمعالجة وتحليل البيانات المجمّعة وفقًا لمجموعة من القواعد المحددة مسبقًا أو باستخدام تحليلات متقدمة وخوارزميات تعلم آلي. يساعد هذا المكوّن في التعرف على أنماط الهجمات المعقدة والتهديدات متعددة المراحل التي قد تقوّت على حلول أمنية أحادية النقطة.

الكشف عن الحوادث والاستجابة لها: يجب أن يسهّل نظام SIEM الفعّال ليس فقط الكشف عن الحوادث الأمنية بل أيضًا الاستجابة لها. يشمل ذلك التكامل مع أدوات ومنصات أمنية أخرى مثل: SOAR. تساعد آليات الاستجابة المؤتمتة في احتواء التهديدات بسرعة، بينما تُوجّه التدفقات المحددة مسبقًا وأدلة التشغيل المحليين في التحقيق ومعالجة الحوادث. هذا المكوّن يضمن نهجًا منظمًا وفعّالًا لإدارة الحوادث، مما يقلل من الأضرار المحتملة الناتجة عن اختراقات الأمن.


دمج معلومات التهديد: إدماج تغذيات معلومات التهديد داخل SIEM يعزز من قدرته على الكشف عن التهديدات المعروفة. توفر معلومات التهديد بيانات محدّثة حول: عناوين IP ضارة، نطاقات مشبوهة، و التواريخ المرتبطة بالأنشطة الخبيثة. من خلال دمج هذه البيانات، يمكن لـ SIEM تحديد التهديدات وحظرها

بشكل استباقي حتى قبل حدوثها. هذا التكامل يساعد المؤسسات على البقاء محمية ضد التهديدات السيبرانية المتطورة باستمرار.

لوحات التحكم والتقارير: تُعد الرؤية والاتصال عنصرين حيويين في أي SIEM فعال. توفر لوحات التحكم تمثيلاً رسومياً للوضع الأمني، مما يمكّن أصحاب المصلحة من فهم مشهد التهديد الحالي بسرعة. تشمل ميزات إعداد التقارير القابلة للتخصيص القدرة على إنشاء تقارير مفصلة تُستخدم لأغراض التدقيق، الامتثال، وتقديم المعلومات للإدارة. هذه الميزات أساسية لتقديم رؤية دقيقة وتسهيل اتخاذ القرارات المستتيرة داخل المؤسسة.

القابلية للتوسع والأداء: مع نمو المؤسسات، يجب أن تكون أنظمة SIEM قادرة على التوسع للتعامل مع أحجام بيانات متزايدة دون التأثير على الأداء. هذا يضمن أن SIEM يمكنه الاستمرار في العمل بشكل مثالي حتى مع تطور احتياجات المؤسسة.

الامتثال والحوكمة: يساعد SIEM الفعال المؤسسات على تلبية التزامات الامتثال عبر توفير: مسارات تدقيق شاملة، سجلات مفصلة، و الوثائق المطلوبة. يجب أن يدعم النظام الامتثال لمعايير ولوائح تنظيمية مثل: GDPR، HIPAA، PCI-DSS. هذا يُظهر التزام المؤسسة بأمن البيانات ويعزز من الثقة والمصداقية.



1.3 مكونات نظام SIEM الفعال

الفصل الثاني: تجهيز بيئة العمل

2.1 مقدمة عامة

يعتمد المشروع على منظومة Wazuh SIEM لجمع وتحليل السجلات الأمنية من الأنظمة المختلفة، إلى جانب استخدام جدار الحماية pfSense كمصدر رئيسي لبيانات الشبكة وحركة المرور، بينما يتم تشغيل كامل البيئة على نظام التشغيل Linux Ubuntu لما يوفره من استقرار ومرونة ودعم واسع لتطبيقات الأمن السيبراني. ويتيح هذا التكامل بين مكونات النظام إمكانية تحليل السجلات بشكل مركزي، ثم تطبيق خوارزميات الذكاء الاصطناعي لاكتشاف الأنماط الشاذة التي قد تشير إلى محاولات اختراق في مراحلها المبكرة.

من خلال هذا النهج، يسعى المشروع إلى تحقيق توازن فعال بين الدقة في الكشف، تقليل الإنذارات الكاذبة، وسرعة الاستجابة للتهديدات، مما يجعله مناسباً للأغراض البحثية والأكاديمية، وقابلاً للتطبيق العملي في البيئات الواقعية التي تتطلب أنظمة مراقبة أمنية ذكية وقابلة للتوسع

2.2 نظام التشغيل: Linux Ubuntu

لمحة عن Ubuntu

يُعد Ubuntu أحد أكثر توزيعات Linux انتشاراً واستخداماً في بيئات الخوادم والبنية التحتية للشبكات، حيث يتميز بكونه نظام تشغيل مفتوح المصدر مبني على نواة Linux، مع دعم واسع من المجتمع التقني والشركات. يتم الاعتماد في هذا المشروع على إصدار LTS (Long Term Support) لما يوفره من استقرار عالٍ، تحديثات أمنية طويلة الأمد، وتقليل مخاطر التوقف أو الأعطال أثناء تشغيل النظام لفترات طويلة.

كما يتميز Ubuntu بسهولة الإدارة، وضوح هيكل النظام، وتوافر عدد كبير من الحزم البرمجية الجاهزة، مما يجعله خياراً مثالياً لاستضافة أنظمة تحليل أمني متقدمة مثل SIEM وخوارزميات الذكاء الاصطناعي.

دور Ubuntu في المشروع

يؤدي نظام Ubuntu دور المنصة المركزية التي يتم فوقها تشغيل جميع مكونات المشروع، حيث يتم استخدامه في:

- استضافة خادم Wazuh Server بكامل مكوناته، بما يشمل مدير الأحداث، المفهرس، ولوحة التحكم.
- تشغيل خدمات تحليل السجلات الأمنية القادمة من الأنظمة المختلفة، سواء كانت سجلات نظام، شبكة، أو جدار حماية.
- توفير بيئة مناسبة لتشغيل خوارزمية Isolation Forest باستخدام لغة Python، مع دعم المكتبات الخاصة بتحليل البيانات والتعلم الآلي.
- إدارة موارد النظام (المعالج، الذاكرة، التخزين) بكفاءة عالية، مما يضمن استقرار النظام حتى عند معالجة كميات كبيرة من السجلات والأحداث الأمنية.

مقارنة Ubuntu مع Kali Linux

عند مقارنة Ubuntu مع Kali Linux، يتضح أن كل نظام صُمم لغرض مختلف. Kali Linux موجه أساسًا لاختبارات الاختراق والهجمات الأمنية، ويحتوي على أدوات هجومية جاهزة، لكنه لا يُعد خيارًا مناسبًا للعمل المستمر أو لاستضافة أنظمة إنتاجية طويلة الأمد.

في المقابل، يتميز Ubuntu باستقراره العالي، ملاءمته لبيئات الخوادم، وانخفاض استهلاكه للموارد، مما يجعله الأنسب لاستضافة منظومة SIEM وتشغيل خوارزميات الذكاء الاصطناعي بشكل دائم وموثوق، خاصة في السياقات الأكاديمية والبحثية.

المعيار	Ubuntu Linux	Kali Linux
الغرض الأساسي	تشغيل الخوادم والأنظمة الإنتاجية	اختبارات الاختراق والهجوم
الاستقرار	عالي جدًا ومناسب للعمل طويل الأمد	أقل استقرارًا للاستخدام المستمر
بيئة الخادم	مهيأ لاستضافة خدمات SIEM وتحليل البيانات	غير مخصص لاستضافة خوادم إنتاجية
استهلاك الموارد	متوازن ومناسب للأنظمة التحليلية	أعلى بسبب كثرة الأدوات المثبتة
التحديثات	منتظمة ومستقرة (LTS)	تحديثات سريعة وقد تسبب عدم استقرار
الملاءمة للمشروع	عالية جدًا	منخفضة

2.1 مقارنة Ubuntu مع Kali linux

سبب اختيار Ubuntu

تم اختيار Ubuntu للأسباب التالية:

1. يتمتع بدرجة عالية من الاستقرار، وهو عامل حاسم لتشغيل أنظمة المراقبة الأمنية بشكل متواصل.
2. مصمم أساسًا لبيئات الخوادم وليس للاختبار أو الهجوم، مما يعزز من موثوقية البيئة.
3. يقدم دعمًا ممتازًا لتطبيقات SIEM وأنظمة تحليل السجلات.
4. يتكامل بسلاسة مع أدوات الذكاء الاصطناعي ومكتبات Python الخاصة بالتعلم الآلي.
5. مناسب للتطبيق العملي الحقيقي وليس للاستخدام التجريبي فقط.

2.3 منظومة SIEM

لمحة عن Wazuh

يُعد Wazuh نظامًا مفتوح المصدر يجمع بين خصائص SIEM و XDR، حيث يوفر إمكانيات متقدمة لجمع وتحليل السجلات، كشف التسلل، مراقبة سلامة الملفات، واكتشاف الأنشطة غير الطبيعية. يتميز Wazuh بمرونته العالية وقدرته على العمل في بيئات متنوعة، مع دعم واسع للتكامل مع أدوات خارجية، بما في ذلك خوارزميات الذكاء الاصطناعي.

مكونات Wazuh

تتكون منظومة Wazuh من عدة مكونات مترابطة تعمل معًا لتوفير رؤية أمنية شاملة:

- Wazuh Manager: المسؤول عن تحليل الأحداث، تطبيق القواعد الأمنية، وتوليد التنبيهات.
- Wazuh Indexer: يتولى تخزين وفهرسة البيانات بشكل يسمح بالبحث السريع والتحليل المتقدم.
- Wazuh Dashboard: واجهة رسومية تفاعلية لعرض السجلات، التنبيهات، والمؤشرات الأمنية.
- Wazuh Agent: يتم تثبيته على الأنظمة الطرفية لجمع السجلات وإرسالها إلى الخادم المركزي.

دور Wazuh في المشروع

في هذا المشروع، يلعب Wazuh دور العمود الفقري لمنظومة التحليل الأمني، حيث يقوم بـ:

- جمع السجلات الأمنية من الأنظمة المختلفة.
- تنفيذ تحليل أولي للأحداث باستخدام القواعد التقليدية.

- تزويد خوارزمية Isolation Forest بالبيانات اللازمة لاكتشاف السلوكيات الشاذة.
- عرض التنبيهات المبكرة التي تشير إلى احتمالية حدوث اختراق.

مقارنة Wazuh مع Splunk SIEM

على الرغم من قوة Splunk، إلا أنه نظام تجاري مغلق نسبيًا، وتكلفته العالية تحد من استخدامه في الأبحاث الأكاديمية. بالمقابل، يوفر Wazuh تحكمًا كاملاً بالبيانات، مرونة عالية في التخصيص، وإمكانية دمج خوارزميات الذكاء الاصطناعي بسهولة، مما يجعله أكثر ملاءمة للأبحاث والتجارب العلمية.

المعيار	Wazuh SIEM	Splunk SIEM
نوع النظام	مفتوح المصدر	تجاري
التكلفة	مجاني	مرتفعة
التحكم بالبيانات	كامل	محدود نسبيًا
سهولة الدمج مع الذكاء الاصطناعي	عالية	متوسطة
المرونة في التخصيص	عالية جدًا	محدودة بقيود ترخيص
الملاءمة للأبحاث الأكاديمية	ممتازة	ضعيفة
الاستخدام في المشروع	مناسب جدًا	غير عملي

2.2 مقارنة Wazuh مع Splunk SIEM

سبب اختيار Wazuh

تم اختيار Wazuh للأسباب التالية:

1. كونه مفتوح المصدر يجعله مثاليًا للأبحاث الأكاديمية.
2. يوفر تحكمًا كاملاً بالبيانات دون قيود تجارية.
3. يسهل دمج مع خوارزميات الذكاء الاصطناعي.

4. منخفض التكلفة مقارنة بالحلول التجارية.
5. يتمتع ببنية واضحة وقابلة للتوسع مستقبلاً.

2.4 جدار الحماية: pfSense

لمحة عن pfSense

، ويُستخدم لإدارة حركة المرور FreeBSD هو جدار حماية مفتوح المصدر مبني على نظام pfSense الشبكية وتطبيق سياسات الأمان. يتميز بواجهة سهلة، دعم قوي للمراقبة الشبكية، وإمكانية تسجيل الأحداث الأمنية بالتفصيل.

دور pfSense في المشروع

يؤدي pfSense دور خط الدفاع الأول في البيئة، حيث يقوم بـ:

- حماية الشبكة الداخلية من التهديدات الخارجية.
- مراقبة حركة المرور وتحليلها.
- كشف السلوكيات الشبكية المشبوهة.
- تزويد Wazuh بسجلات الشبكة لاستخدامها في التحليل الذكي.

مقارنة pfSense مع Cisco ASA

على الرغم من قوة Cisco ASA، إلا أن تكلفته العالية وكونه نظامًا تجاريًا يجعلان pfSense خيارًا أفضل للأغراض التعليمية والبحثية، خاصة مع مرونته العالية وسهولة تخصيصه.

المعيار	pfSense	Cisco ASA
نوع النظام	مفتوح المصدر	تجاري
التكلفة	مجاني	مرتفعة
سهولة الإعداد	سهولة نسبيًا	معقدة
تسجيل الأحداث (Logging)	مفصل وقابل للتخصيص	محدود نسبيًا
التكامل مع SIEM	سهل	يتطلب إعداد إضافي
الملاءمة الأكاديمية	ممتازة	ضعيفة
الاستخدام في المشروع	مناسب جدًا	غير عملي

2.3 مقارنة pfSense مع CiscoASA

سبب اختيار pfSense

تم اختيار pfSense للأسباب التالية:

1. مفتوح المصدر ومجاني.
2. يوفر دعمًا قويًا لمراقبة الشبكة.
3. يتكامل بسهولة مع Wazuh.
4. مناسب للبيئات الأكاديمية.
5. قابل للتوسع والتخصيص حسب متطلبات المشروع.

2.5 الأداة Sysmon:

لمحة عن Sysmon

Sysmon هو أداة متقدمة لمراقبة النظام ضمن بيئة Windows، طورته Microsoft Sysinternals، وتعمل كخدمة (Service) تقوم بتسجيل أحداث تفصيلية عالية الدقة داخل سجل أحداث Windows (Event Log).

تتميز الأداة بقدرتها على تتبع سلوك النظام بشكل عميق، حيث تقوم بتسجيل معلومات مثل:

- إنشاء العمليات (Process Creation)
- العلاقات بين العمليات (Parent-Child Processes)
- أوامر التشغيل (Command Line)
- الاتصالات الشبكية (Network Connections)
- التغييرات على الريجستري (Registry Modifications)
- تحميل الملفات التنفيذية (Image Loading)

دور Sysmon في المشروع

لعب Sysmon دوراً محورياً في هذا المشروع، حيث وفر بيانات غنية ومفصلة تم استخدامها في:

- جمع بيانات سلوكية دقيقة عن نشاط المستخدم داخل النظام
- تحليل العمليات والـ command line لاكتشاف الأنشطة غير الطبيعية
- بناء Dataset واقعي يعكس الاستخدام الحقيقي للنظام
- تغذية نموذج الذكاء الاصطناعي بميزات (Features) ذات جودة عالية
- دعم مفهوم XDR من خلال توفير رؤية عميقة على مستوى الـ Endpoint

وقد تم إرسال هذه البيانات إلى منصة Wazuh لتحليلها وتخزينها، ومن ثم استخدامها في مراحل المعالجة والتدريب.

مقارنة بين Sysmon و Windows Standard Logs

1. Windows Standard Logs

سجلات Windows التقليدية (مثل Security Logs و System Logs) توفر معلومات أساسية عن النظام، مثل:

- تسجيل الدخول والخروج

-عض الأحداث الأمنية

-أخطاء النظام

-لكنها تعاني من:

-نقص في التفاصيل

-غياب معلومات مهمة مثل Command Line

-صعوبة تتبع سلوك العمليات بشكل كامل

Sysmon .2

-في المقابل، يقدم Sysmon:

-تفاصيل دقيقة جداً لكل عملية

-تسجيل كامل للأوامر المنفذة

-إمكانية تتبع العلاقات بين العمليات

-رؤية أعمق لسلوك النظام

سبب اختيار Sysmon في المشروع

تم اختيار Sysmon بدلاً من الاعتماد على Windows Logs التقليدية للأسباب التالية:

- توفير بيانات غنية ومفصلة ضرورية لتحليل السلوك
- دعم قوي لعمليات Anomaly Detection باستخدام الذكاء الاصطناعي
- القدرة على استخراج Features مهمة مثل:

Process.

parent_process.

command_line.

- تحسين دقة الكشف وتقليل الاعتماد على القواعد الثابتة
- التوافق مع منصة Wazuh وسهولة دمج البيانات ضمن نظام SIEM

الخلاصة

إن اعتماد بيئة عمل مبنية على Linux Ubuntu كنظام تشغيل مستضيف، ومنظومة Wazuh SIEM، وجدار الحماية pfSense، يوفر منصة متكاملة وآمنة للكشف المبكر عن الاختراقات باستخدام الذكاء الاصطناعي. لم يكن اختيار هذه المكونات عشوائياً، بل جاء نتيجة مقارنة علمية مدروسة مع بدائل تجارية، أظهرت تفوق الحلول المفتوحة المصدر من حيث المرونة، التكلفة، والملاءمة البحثية، مما يجعل هذه البيئة أساساً قوياً لتطوير أنظمة كشف اختراقات ذكية وفعالة.

الفصل الثالث: الحل المقترح

3.1 مقدمة عامة للفصل

بعد العرض النظري المفصل في الفصلين الأول والثاني، وما تضمنناه من تأطير لمفاهيم كشف التسلّل ودور أنظمة SIEM والتحديات المصاحبة، ينتقل هذا الفصل إلى تقديم حل عملي مقترح يهدف إلى الكشف المبكر عن محاولات الاختراق بالاعتماد على الذكاء الاصطناعي ضمن بيئة SIEM تشغيلية. يركز الحل على خط أنابيب (Pipeline) متكامل يبدأ من استيعاب البيانات وتطبيعها، مروراً بـ اشتقاق السمات السلوكية ذات الدلالة الأمنية، ثم نمذجة الشذوذ بأساليب تعلم آلي غير خاضعة للإشراف، وصولاً إلى توليد إنذارات قابلة للتنفيذ وربطها بتدفقات الاستجابة. هذا الانتقال من التنظير إلى التطبيق يتسق مع الأهداف العامة للمشروع في تقليص زمن الاكتشاف وخفض الإيجابيات الكاذبة وتعزيز الصيد الاستباقي للتهديدات. يركّز النموذج المرجعي للحل على حالة استخدام محورية هي محاولات كسر كلمات المرور (Brute Force) لخدمة SSH؛ إذ تُعدّ هذه الهجمة مثالاً مناسباً لإظهار قيمة التحليل السلوكي القائم على تجميع الأحداث زمنياً وقياس مؤشرات مثل: SYN, Total forward packets, Total backward packets, Flow duration. تُغذي هذه المؤشرات خوارزميات كشف الشذوذ (مثل Isolation Forest) لتمييز الأنماط غير المعتادة دون الحاجة إلى بيانات موسومة سلفاً، مع تعيين مستويات خطورة قابلة للضبط وعتبات تشغيلية تُراعي طبيعة الضوضاء في بيانات المؤسسات.

3.2 بنية الحل المقترح

طبقة جمع البيانات (Data Collection Layer): تبدأ العملية من خلال جمع سجلات محاولات الدخول (Logs) في صيغة CSV، حيث تحتوي على الحقول الأساسية مثل الوقت، وعنوان الـIP، واسم المستخدم، ونوع الخدمة، وحالة المحاولة. هذه البيانات تمثل المصدر الخام الذي يُبنى عليه التحليل.

طبقة المعالجة والاستخراج (Processing & Feature Extraction Layer): في هذه المرحلة تُحوّل السجلات الخام إلى سمات (Features) إحصائية قابلة للتحليل مثل عدد المحاولات الكلي، عدد المحاولات الفاشلة، معدل الفشل، وعدد المستخدمين المستهدفين. هذه المرحلة أساسية لأنها تختصر البيانات وتبرز المؤشرات الأكثر دلالة على هجمات Brute Force.

طبقة الذكاء الاصطناعي (AI Detection Layer): يتم في هذه الطبقة تطبيق خوارزمية Isolation Forest التي تقوم بعزل السلوكيات الشاذة عن السلوكيات الطبيعية، استنادًا إلى السمات المستخرجة. أي محاولة دخول ذات خصائص غير اعتيادية (عدد هائل من المحاولات الفاشلة، معدل فشل مرتفع، أو استهداف عدة مستخدمين من نفس الـ IP) يتم تصنيفها كهجوم محتمل.

طبقة التكامل والعرض (Integration & Visualization Layer): بعد اكتشاف الهجمات، يتم إرسال النتائج إلى منصة Wazuh، حيث تُعرض في لوحات مراقبة تفاعلية (Dashboards) تتضمن جداول، مخططات زمنية، ورسوم بيانية توضح الهجمات المكتشفة ومصادرها وأوقاتها. هذه الطبقة تجعل الحل عمليًا وقابلًا للتطبيق في بيئات عمل حقيقية.


هذا التصميم المعماري يوفر إطارًا متكاملًا يجمع بين جمع البيانات، المعالجة، التحليل الذكي، والعرض البصري، مما يجعله حلًا متوازنًا قادرًا على دعم المحللين الأمنيين في مهام الكشف المبكر والاستجابة للهجمات.

3.3 شرح آلية عمل الخوارزمية (Isolation Forest)

خوارزمية Isolation Forest (غابة العزل) هي خوارزمية مخصصة لـ الكشف عن الشذوذ (Anomaly Detection)، طُوِّرت عام 2008، وتتميز بفعاليتها مع البيانات الكبيرة وقدرتها على التعامل مع الحالات النادرة. بخلاف خوارزميات التصنيف التقليدية، فإنها لا تحاول نمذجة السلوك الطبيعي ثم البحث عن الانحرافات، بل تعتمد على مبدأ أن النقاط الشاذة تكون أسهل وأسرع في العزل من النقاط الطبيعية.

3.3.1 الفكرة الرئيسية


النقاط الطبيعية (Normal Data Points) متقاربة في التوزيع وتحتاج إلى عدد أكبر من عمليات التقسيم حتى يتم فصلها. النقاط الشاذة (Anomalies) بعيدة عن التجمعات الرئيسية، ويمكن عزلها بعدد قليل من عمليات التقسيم. أي أن الخوارزمية تعتبر عملية عزل النقطة مقياسًا لمدى شذوذها: كلما كان العزل أسرع، كلما ارتفعت احتمالية كون النقطة شاذة.



3.1 آلية عمل خوارزمية isolation forest

تُظهر هذه الصورة المبدأ الأساسي لعمل خوارزمية Isolation Forest، والتي تُستخدم بشكل واسع في اكتشاف الشذوذات (Anomalies) ضمن البيانات. الفكرة العامة تقوم على إنشاء مجموعة من الأشجار العشوائية تسمى iTrees، حيث يتم تقسيم البيانات بشكل متكرر إلى أن يتم عزل كل نقطة بيانات في مسار معين داخل الشجرة. في الصورة نرى أن هناك عدة أشجار (iTree 1, iTree 2 ... iTree n). كل شجرة تعمل بشكل مستقل على تقسيم البيانات، والنتيجة النهائية هي دمج قرارات هذه الأشجار لتحديد ما إذا كانت النقطة تمثل سلوكًا طبيعيًا أم شاذًا. النقاط الفاتحة اللون تمثل بيانات طبيعية (Normal Data Point)، حيث تحتاج عادةً إلى مسار طويل داخل الأشجار حتى يتم عزلها، مما يعني أنها تتشابه مع بقية البيانات. أما النقاط الغامقة اللون فهي تمثل الشذوذ (Anomaly)، حيث يتم عزلها بسرعة عبر مسار قصير داخل الشجرة، لأنها مختلفة عن الأنماط المعتادة في البيانات. بهذا الأسلوب تصبح الخوارزمية قادرة على التمييز بين محاولات الدخول الشرعية (التي تتوزع بشكل طبيعي) ومحاولات الهجوم مثل Brute Force (التي تظهر كسلوك مختلف وسهل العزل).

3.4 تجهيز البنية الشبكية و العملية



3.2 بنية النظام

الصورة تُظهر ثلاث شبكات منطقية، لكل واحدة هدف:

(1) شبكة خارجية/حقيقية عبر 192.168.1.0/24 Bridged adapter:

- تمثل شبكة الراوتر/الإنترنت في بيئة المستخدم.
- pfSense يمتلك عليها واجهة بعنوان: 192.168.1.113 (WAN/Bridged) متصلة بالإنترنت.
- خادم Wazuh ظاهر بعنوان: 192.168.1.122 ضمن نفس النطاق، لتسهيل الاتصال وإرسال الـ Syslog عبر الشبكة الفعلية/المجسرة.

(2) شبكة 192.168.56.0/24 Host-only:

- شبكة "إدارة/ربط داخلي" بين جهاز المضيف (Host) والآلات الافتراضية بدون الاعتماد على الراوتر.
- pfSense لديه عليها عنوان: 192.168.56.101
- جهاز المضيف (ويندوز) لديه: 192.168.56.1

• فائدتها: قناة اتصال ثابتة لإدارة المختبر حتى لو تغيرت إعدادات الشبكة الخارجية.

(3) شبكة داخلية معزولة 10.10.10.0/24 (Internal network):

• هذه شبكة الاختبار للهجوم والدفاع داخل المختبر.

• pfSense يعمل كبوابة (Gateway) لها بعنوان: 10.10.10.1

• يوجد داخلها:

• جهاز مهاجم (Parrot) لتنفيذ الهجمات داخل بيئة آمنة ومعزولة و لها عنوان: 10.10.10.101

3.5 الربط بين Pfsense و Wazuh server

The image shows two parts: a web interface for configuring remote log servers and a terminal window showing the configuration file content.

Web Interface:

- Remote log servers:** 192.168.1.131:514
- Remote Syslog Contents:**
 - ☒ Everything
 - ☒ System Events
 - ☒ Firewall Events
 - ☐ DNS Events (Resolver/unbound, Forwarder/dnsmasq, filterdns)
 - ☐ DHCP Events (DHCP Daemon, DHCP Relay, DHCP Client)
 - ☐ PPP Events (PPPoE WAN Client, L2TP WAN Client, PPTP WAN Client)
 - ☒ General Authentication Events
 - ☐ Captive Portal Events
 - ☐ VPN Events (IPsec, OpenVPN, L2TP, PPPoE Server)
 - ☐ Gateway Monitor Events
 - ☐ Routing Daemon Events (RADVD, UPhP, RIP, OSPF, BGP)
 - ☐ Network Time Protocol Events (NTP Daemon, NTP Client)
 - ☐ Wireless Events (hostapd)

Syslog sends UDP datagrams to port 514 on the specified remote syslog server, unless another port is specified. Be sure to set syslogd on the remote server to accept syslog messages from pfSense.

Terminal Output (GNU nano 4.8):

```
/var/ossec/etc/ossec.conf
<protocol>tcp</protocol>

<allowed-ips>192.168.1.106</allowed-ips>
</remote>

<remote>
  <connection>syslog</connection>
  <port>514</port>
  <protocol>udp</protocol>

  <allowed-ips>0.0.0.0/0</allowed-ips>
</remote>
```

3.3 الربط بين wazuh و pfsense

تم إعداد خادم Wazuh ليعمل كمستقبل Syslog (Syslog Receiver) من خلال تفعيل إعدادات <remote> في ملف ossec.conf باستخدام البروتوكول UDP على المنفذ 514. وفي المقابل، تم ضبط جدار الحماية pfSense لإرسال سجلاته إلى عنوان الخادم (192.168.1.113:514) متضمنة سجلات النظام والجدار الناري. تتيح هذه الخطوة جمع وتحليل بيانات الشبكة من المصدر نفسه، مما يُسهّل تطبيق خوارزميات الكشف المبكر عن الهجمات وتحليل الأنماط ضمن بيئة الـ SIEM المقترحة.

3.6 تهيئة القواعد و Decoders

```

root@ubuntu: /var/ossec/ai
GNU nano 4.8 /var/ossec/etc/decoders/local_decoder.xml
decoder name="pfsense-filterlog-with-date"
  <prematch>filterlog</prematch>
</decoder>

root@ubuntu: /var/ossec/ai
GNU nano 4.8 /var/ossec/etc/rules/local_rules.xml
<!-- Local rules -->
<!-- Modify it at your will. -->
<!-- Copyright (C) 2015, Wazuh Inc. -->
<group name="pfsense,ssh">
  <rule id="200100" level="8">
    <match>,22,</match>
    <description>pfsense SSH traffic detected (destination port 22)</description>
    <group>pfsense,ssh,tcp</group>
  </rule>
</group>

```

3.4 القواعد و Decoders

تمت تهيئة Wazuh لاستقبال سجلات pfSense من نوع filterlog عبر إنشاء Decoder مخصص باستخدام آلية prematch للتعرف الأولي على السجلات المرتبطة بالجدار الناري. بعد ذلك تم تطوير قاعدة كشف محلية ضمن local_rules.xml بهدف رصد حركة SSH من خلال مطابقة نمط يشير إلى منفذ الوجهة 22، مع ضبط مستوى الخطورة (level=8) وتصنيف الحدث ضمن مجموعات (pfsense, ssh,)

(tcp). يوضح هذا الإجراء سلسلة التحليل في Wazuh بدءًا من تعريف نمط السجل (Decoding) وصولاً إلى تطبيق منطق الكشف وإنتاج التنبيه (Rule-based Detection).

3.7 تنفيذ هجمة SSH (BRUTE FORCE) لأختبار القواعد العادية (بدون ذكاء اصطناعي)

```
[user@parrot]~$ hydra -l lenovo -P /usr/share/wordlists/rockyou.txt.gz ssh://192.168.1.106
Hydra v9.4 (c) 2022 by van Hauser/THC & David Maciejak - Please do not use in military or secret service organizations, or for illegal purposes (this is non-binding, these *** ignore laws and ethics anyway).


Hydra (https://github.com/vanhauser-thc/thc-hydra) starting at 2026-01-09 11:52:30
[WARNING] Many SSH configurations limit the number of parallel tasks, it is recommended to reduce the tasks: use -t 4
[WARNING] Restorefile (you have 10 seconds to abort... (use option -I to skip waiting)) from a previous session found, to prevent overwriting, ./hydra.restore
[DATA] max 16 tasks per 1 server, overall 16 tasks, 14344399 login tries (l:1/p:14344399), ~896525 tries per task
[DATA] attacking ssh://192.168.1.106:22/
[STATUS] 156.00 tries/min, 156 tries in 00:01h, 14344245 to do in 1532:31h, 14 a
```

3.5 تنفيذ الهجمة

ظهر هذه الصورة تنفيذ تجربة محاكاة لهجوم تخمين كلمات المرور (SSH Brute Force) ضمن بيئة مختبرية معزولة باستخدام نظام Parrot OS كجهاز مُهاجم. تم تشغيل أداة اختبار كلمات المرور Hydra لاستهداف خدمة SSH على جهاز ضمن نفس الشبكة (عنوان IP ظاهر في الشاشة)، مع الاعتماد على قائمة كلمات مرور (Wordlist) بهدف توليد عدد كبير من محاولات تسجيل الدخول المتتالية. أثناء التنفيذ تعرض الأداة مؤشرات تشغيلية مثل معدل المحاولات في الدقيقة وعدد المهام المتوازية وحالة الجلسة، ما يوضح الطبيعة التكرارية للهجوم. تُستخدم هذه الخطوة في سياق الدراسة لتوليد سجلات واقعية يمكن إرسالها إلى منظومة SIEM/Wazuh وتحليلها لاستخراج الأنماط، وبناء قواعد/نماذج كشف مبكر عن محاولات الاختراق، مع التأكيد أن التجربة تمت لأغراض بحثية وتعليمية ضمن نطاق مُصرَّح به.

3.8 النقاط السجلات و توليد الإنذارات

✓	Jan 10 22:06:30	OPT1	USER_RULE (1767041749)	10.10.10.120:34260	192.168.1.106:22	TCP:S
✓	Jan 10 22:06:30	OPT1	USER_RULE (1767041749)	10.10.10.120:34238	192.168.1.106:22	TCP:S
✓	Jan 10 22:06:30	OPT1	USER_RULE (1767041749)	10.10.10.120:34262	192.168.1.106:22	TCP:S
✓	Jan 10 22:06:30	OPT1	USER_RULE (1767041749)	10.10.10.120:34246	192.168.1.106:22	TCP:S
✓	Jan 10 22:06:30	OPT1	USER_RULE (1767041749)	10.10.10.120:34278	192.168.1.106:22	TCP:S
✓	Jan 10 22:06:30	OPT1	USER_RULE (1767041749)	10.10.10.120:34284	192.168.1.106:22	TCP:S



3.6 توليد الانذارات

بعد تنفيذ هجمة Brute Force على خدمة SSH من جهاز المهاجم ضمن الشبكة الداخلية، تمر حركة المرور أولاً عبر pfSense الذي يعمل كبوابة (Gateway/Firewall) بين الشبكات. يقوم pfSense بتسجيل كل محاولة اتصال ضمن Firewall Logs (filterlog)، حيث تظهر الحزم المتجهة إلى منفذ الوجهة TCP/22 على جهاز الضحية مع تكرار سريع للمحاولات، وهو نمط سلوكي مميز لهجمات التخمين. بعد ذلك يتم تفعيل ميزة Remote Syslog في pfSense لإرسال هذه السجلات بشكل فوري إلى خادم Wazuh عبر بروتوكول Syslog (UDP/514). عند وصول السجلات إلى Wazuh، يتم تمريرها عبر مرحلة Decoding للتعرف على أنها سجلات pfSense (باستخدام decoder محلي يعتمد على prematch لكلمة filterlog)، ثم تُطبق قواعد الكشف (Rules) المعرفة ضمن local_rules.xml؛ وفي هذه الحالة تقوم القاعدة ذات المعرف rule.id=200100 برصد الاتصالات المتعلقة بـ SSH اعتماداً على ظهور منفذ 22 ضمن السجل. نتيجة ذلك يُولد Wazuh تنبيهاً (Alert) بمستوى خطورة محدد (level=8)، ويتم فهرسة الحدث ضمن wazuh-alerts-* ليظهر مباشرة في واجهة Wazuh

Dashboard/Discover على شكل عدد كبير من الـ hits مرتبط بزمان الهجوم، مما يؤكد نجاح سلسلة

الرصد من (الهجوم → تسجيله في pfSense → إرساله عبر Syslog → تحليله في Wazuh → إصدار Alert).

3.9 اعداد و ربط Wazuh Agent مع Wazuh Manager

Agents (1) [Deploy new agent](#) [Refresh](#) [Export formatted](#) [More](#) ▼

status=active

☐	ID ↑	Name	IP address	Group(s)	Operating system	Cluster node	Version	Status	Actions
☐	006	DESKTOP-5HLISCS	192.168.1.106	default	Microsoft Windows 10 Pro 10.0.19045.6466	node01	v4.14.1	active info	edit

Rows per page: 10 ▼

 Wazuh Agent

×

Manage

View

Help

Wazuh v4.14.1

Agent: DESKTOP-5HLISCS (006) - any

Status: Running

Manager IP:

Authentication key:

Save

Refresh


<https://wazuh.com>

Revision rc2

3.7 اعداد Wazuh Agent

تم في هذه المرحلة إعداد وربط وكيل Wazuh (Agent) على جهاز المستخدم (Endpoint) مع خادم Wazuh المركزي (Manager)، وذلك بهدف جمع البيانات الأمنية وإرسالها إلى النظام المركزي لتحليلها واكتشاف التهديدات. في البداية، تم تثبيت برنامج Wazuh Agent على نظام التشغيل (Windows)، ثم تم تشغيله والتأكد من أن حالته تعمل بشكل طبيعي (Running). بعد ذلك، تم إدخال عنوان IP الخاص بخادم Wazuh Manager داخل إعدادات الـ Agent، وذلك لتمكين الاتصال بين الجهاز والخادم. تم أيضاً إدخال مفتاح المصادقة (Authentication Key)، والذي يتم توليده من خادم Wazuh Manager، ويستخدم للتحقق من هوية الجهاز وضمان الاتصال الآمن بين الطرفين. بعد حفظ الإعدادات، تم التأكد من نجاح عملية الربط من خلال ظهور حالة الاتصال على أنها نشطة (Active) في واجهة Wazuh. يسمح هذا الربط بإرسال جميع السجلات (Logs) من جهاز المستخدم، مثل سجلات النظام وسجلات Sysmon، إلى خادم Wazuh، حيث يتم تحليلها وربطها مع باقي البيانات القادمة من الشبكة، مما يساهم في تحسين قدرة النظام على اكتشاف الهجمات والأنشطة المشبوهة بشكل دقيق وفي الوقت الحقيقي.

3.10 جمع و مراقبة سجلات Sysmon على نظام Windows



3.9 عرض سجلات Sysmon

تم في هذه المرحلة استخدام أداة Sysmon (System Monitor) على نظام Windows بهدف جمع سجلات تفصيلية حول سلوك النظام والتطبيقات. تُعد Sysmon أداة متقدمة تابعة لمجموعة Sysinternals، وتقوم بتسجيل الأنشطة المهمة مثل إنشاء العمليات (Process Creation)، والوصول إلى الملفات، والاتصالات الشبكية، مما يوفر رؤية أعمق لسلوك النظام مقارنة بالسجلات التقليدية. بعد تثبيت Sysmon وتفعيله باستخدام إعدادات مناسبة، تم التأكد من بدء تسجيل الأحداث داخل أداة Event Viewer ضمن المسار: Microsoft-Windows-Sysmon/Operational.

كما يظهر في الصورة، يتم تسجيل الأحداث المختلفة مثل 1 Event ID، والذي يشير إلى عملية إنشاء جديدة (Process Create). يتضمن هذا الحدث معلومات مهمة مثل اسم العملية، وقت التنفيذ، المستخدم، ومسار الملف، مما يساعد في تحليل سلوك النظام واكتشاف الأنشطة المشبوهة. تُستخدم هذه السجلات لاحقاً في بناء Dataset سلوكي يعتمد على استخراج ميزات محددة، مثل عدد العمليات أو الأوامر المنفذة، ليتم تحليلها باستخدام خوارزميات الذكاء الاصطناعي للكشف عن الأنماط غير الطبيعية (Anomalies).

3.11 مرحلة جمع و تحليل السجلات الأمنية باستخدام Wazuh

```

jad@jad-VirtualBox:~/Desktop$ sudo ls /var/ossec/logs/archives/2026/Apr
[sudo] password for jad:
ossec-archive-10.json.sum  ossec-archive-13.log.gz  ossec-archive-18.json.sum
ossec-archive-10.log.sum  ossec-archive-13.log.sum  ossec-archive-18.log.gz
ossec-archive-11.json     ossec-archive-14.json    ossec-archive-18.log.sum
ossec-archive-11.log      ossec-archive-14.log     ossec-archive-19.json
ossec-archive-13.json     ossec-archive-15.json    ossec-archive-19.log
ossec-archive-13.json.gz  ossec-archive-15.log
ossec-archive-13.json.sum ossec-archive-18.json.gz
jad@jad-VirtualBox:~/Desktop$

```

3.10 ملفات سجلات Wazuh المخزنة ضمن مجلد archive

في هذه المرحلة تم جمع البيانات الأمنية من الأنظمة المختلفة باستخدام منصة Wazuh، حيث تم الاعتماد على Wazuh Manager لتجميع السجلات القادمة من الأجهزة المرتبطة (Agents) مثل نظام Windows. يقوم Wazuh بتخزين هذه السجلات بشكل منظم داخل مجلد الأرشيفات، كما يظهر في الصورة، ضمن المسار: `/var/ossec/logs/archives/`. حيث يتم حفظ السجلات بصيغة JSON في ملفات يومية مثل: `ossec-archive-13.json` و `ossec-archive-14.json` و `ossec-archive-15.json`. تحتوي هذه الملفات على بيانات تفصيلية تشمل الأحداث الأمنية المختلفة، مثل سجلات Sysmon من الأجهزة الطرفية، مما يوفر قاعدة بيانات شاملة لتحليل سلوك النظام. تم استخدام هذه الملفات لاحقاً لاستخراج البيانات وتحويلها إلى Dataset منظم، يتم الاعتماد عليه في مرحلة استخراج الميزات (Feature Extraction) وتدريب نموذج الذكاء الاصطناعي للكشف عن الأنشطة غير الطبيعية.

3.12 تحويل سجلات Sysmon الخام الى Dataset

```
import json
import csv

input_file = "all_data.json"
output_file = "dataset.csv"

with open(input_file, "r") as f, open(output_file, "w", newline='',
encoding="utf-8") as out:
    writer = csv.writer(out)

    writer.writerow([
        "event_id",
        "process",
        "parent_process",
        "command_line",
        "user",
        "timestamp",
        "command_length"
    ])

    for line in f:
        try:
            log = json.loads(line)

            provider = log.get("data", {}).get("win", {}).get("system",
{}).get("providerName", "")

            if provider == "Microsoft-Windows-Sysmon":
```

```

27         system = log.get("data", {}).get("win", {}).get("system",
28     {})
29     data = log.get("data", {}).get("win", {}).get("eventdata",
30     {})
31     event_id = system.get("eventID", "")
32
33     process = data.get("image", "")
34     parent = data.get("parentImage", "")
35     command = data.get("commandLine", "")
36     user = data.get("user", "")
37
38     timestamp = log.get("timestamp", "")
39
40     command_length = len(str(command).split())
41
42     writer.writerow([
43         event_id,
44         process,
45         parent,
46         command,
47         user,
48         timestamp,
49         command_length
50     ])

```

3.11 كود استخراج البيانات من سجلات JSON و تحويلها الى CSV

في هذه المرحلة تم تحويل سجلات النظام (Logs) التي تم جمعها من Wazuh و Sysmon، والتي تكون بصيغة JSON، إلى ملف منظم بصيغة CSV يمكن استخدامه لاحقاً في تحليل البيانات وتدريب نماذج الذكاء الاصطناعي. تم أولاً قراءة ملف السجلات الذي يحتوي على الأحداث بصيغة JSON، حيث تم استخراج المعلومات المهمة من كل سجل، كما تم حساب طول سطر الأوامر (Command Length) كميزة إضافية تساعد في تحليل سلوك الأوامر. تم بعد ذلك تصفية البيانات بحيث يتم الاحتفاظ فقط بالسجلات الصادرة عن Sysmon، لأنها تحتوي على معلومات سلوكية دقيقة حول العمليات والأنشطة داخل النظام.

3.13 مرحلة ترميز البيانات و استخراج الميزات

```
import pandas as pd

df = pd.read_csv("dataset.csv")

df["process"] = df["process"].fillna("unknown").astype(str)
df["parent_process"] = df["parent_process"].fillna("unknown").astype(str)
df["command_line"] = df["command_line"].fillna("").astype(str)
df["user"] = df["user"].fillna("unknown").astype(str)

df["timestamp"] = pd.to_datetime(df["timestamp"], errors="coerce")

df = df.dropna(subset=["timestamp"])

df["time_window"] = df["timestamp"].dt.floor("1min")

# process lowercase
df["process_lower"] = df["process"].str.lower()
df["command_lower"] = df["command_line"].str.lower()

def classify_process(p):
    p = str(p).lower()
    if "powershell" in p:
        return "powershell"
    elif "cmd.exe" in p:
        return "cmd"
    elif "chrome" in p or "msedge" in p or "firefox" in p or "opera" in p:
        return "browser"
    elif (
        "svchost" in p
        or "system32\\services.exe" in p
        or "runtimebroker" in p
        or "searchapp" in p
        or "shellexperiencehost" in p
        or "textinputhost" in p
        or "dllhost" in p
        or "taskhostw" in p
        or "wmiadap" in p
        or "mpcmdrun" in p
    ):
        return "system"
    elif "notepad" in p or "wordpad" in p or "code.exe" in p:
        return "editor"
    elif "explorer.exe" in p:
        return "explorer"
    else:
        return "other"

df["has_getservice"] = df["command_lower"].apply(lambda x: 1 if "get-
service" in x else 0)

df["event_id"] = pd.to_numeric(df["event_id"], errors="coerce").fillna(0)

df["is_event_1"] = (df["event_id"] == 1).astype(int)
df["is_event_3"] = (df["event_id"] == 3).astype(int)
df["is_event_5"] = (df["event_id"] == 5).astype(int)
df["is_event_11"] = (df["event_id"] == 11).astype(int)
df["is_event_12"] = (df["event_id"] == 12).astype(int)
df["is_event_13"] = (df["event_id"] == 13).astype(int)
df["is_event_22"] = (df["event_id"] == 22).astype(int)

df["command_length"] = pd.to_numeric(df["command_length"],
errors="coerce").fillna(0)

grouped = df.groupby("time_window").agg(
    total_events=("event_id", "count"),
    powershell_count=("is_powershell", "sum"),
    cmd_count=("is_cmd", "sum"),
    browser_count=("is_browser", "sum"),
    system_count=("is_system", "sum"),
    editor_count=("is_editor", "sum"),
    explorer_count=("is_explorer", "sum"),
```



```

df["has_getservice"] = df["command_lower"].apply(lambda x: 1 if "get-
service" in x else 0)

df["event_id"] = pd.to_numeric(df["event_id"], errors="coerce").fillna(0)

df["is_event_1"] = (df["event_id"] == 1).astype(int)
df["is_event_3"] = (df["event_id"] == 3).astype(int)
df["is_event_5"] = (df["event_id"] == 5).astype(int)
df["is_event_11"] = (df["event_id"] == 11).astype(int)
df["is_event_12"] = (df["event_id"] == 12).astype(int)
df["is_event_13"] = (df["event_id"] == 13).astype(int)
df["is_event_22"] = (df["event_id"] == 22).astype(int)

df["command_length"] = pd.to_numeric(df["command_length"],
errors="coerce").fillna(0)

grouped = df.groupby("time_window").agg(
    total_events=("event_id", "count"),
    powershell_count=("is_powershell", "sum"),
    cmd_count=("is_cmd", "sum"),
    browser_count=("is_browser", "sum"),
    system_count=("is_system", "sum"),
    editor_count=("is_editor", "sum"),
    explorer_count=("is_explorer", "sum"),

    other_count=("is_other", "sum"),
    whoami_count=("has_whoami", "sum"),
    net_user_count=("has_net_user", "sum"),
    encoded_count=("has_encoded", "sum"),
    nop_count=("has_nop", "sum"),
    getprocess_count=("has_getprocess", "sum"),
    getservice_count=("has_getservice", "sum"),
    event1_count=("is_event_1", "sum"),
    event3_count=("is_event_3", "sum"),
    event5_count=("is_event_5", "sum"),
    event11_count=("is_event_11", "sum"),
    event12_count=("is_event_12", "sum"),
    event13_count=("is_event_13", "sum"),
    event22_count=("is_event_22", "sum"),
    avg_command_length=("command_length", "mean"),
    max_command_length=("command_length", "max"),
).reset_index()

grouped["hour"] = grouped["time_window"].dt.hour

grouped.to_csv("behavioral_dataset.csv", index=False)

print("behavioral_dataset.csv created successfully")
print(grouped.head())
print("Number of windows:", len(grouped))

```

3.12 كود تحويل البيانات الخام الى ميزات عددية و تجميعها ضمن نوافذ زمنية

في هذه المرحلة تم تحويل البيانات الخام (Logs) التي تم جمعها من نظام Wazuh إلى شكل مناسب للاستخدام في نماذج الذكاء الاصطناعي. حيث أن البيانات الأصلية تكون نصية وغير منظمة، لذلك لا يمكن استخدامها مباشرة في التدريب أو التحليل. تم أولاً تنظيف البيانات من القيم الفارغة، وتحويل بعض الحقول مثل أسماء العمليات (process) وسطر الأوامر (command line) إلى أحرف صغيرة لتوحيد الصيغة وتسهيل المعالجة. بعد ذلك، تم تصنيف العمليات إلى فئات رئيسية باستخدام دالة مخصصة، تم أولاً تنظيف البيانات من القيم الفارغة، وتحويل بعض الحقول مثل أسماء العمليات (process) وسطر الأوامر (command line) إلى أحرف صغيرة لتوحيد الصيغة وتسهيل المعالجة. بعد ذلك، تم تصنيف العمليات إلى فئات رئيسية باستخدام دالة مخصصة، ثم تم تحويل هذه الفئات إلى قيم رقمية (Encoding) باستخدام متغيرات ثنائية (0 أو 1)، بحيث يتم تمثيل وجود كل نوع من العمليات ضمن البيانات. كما تم استخراج ميزات إضافية من سطر الأوامر، تم أيضاً تحويل Event ID إلى قيم رقمية، واستخدامها لاشتقاق ميزات تعبر عن نوع الحدث، بعد ذلك، تم تجميع البيانات ضمن نوافذ زمنية (Time Windows) مدتها دقيقة واحدة، حيث تم حساب عدد الأحداث داخل كل نافذة، بالإضافة إلى عدد مرات ظهور كل نوع من العمليات أو الأوامر.

3.14 مرحلة تدريب نموذج كشف الشذوذ باستخدام Isolation Forest

```
import pandas as pd
from sklearn.ensemble import IsolationForest
from sklearn.metrics import confusion_matrix, classification_report,
accuracy_score, precision_score, recall_score, f1_score

df = pd.read_csv("behavioral_dataset.csv")

df = df.fillna(0)

# =====
# Feature Engineering
# =====
df["attack_score"] = (
    df["powershell_count"] * 3 +
    df["cmd_count"] * 2 +
    df["net_user_count"] * 5 +
    df["whoami_count"] * 3 +
    df["encoded_count"] * 4 +
    df["nop_count"] * 3 +
    df["getprocess_count"] * 2 +
    df["getservice_count"] * 2
)

feature_cols = [
```

```

feature_cols = [
    "total_events",
    "powershell_count",
    "cmd_count",
    "browser_count",
    "system_count",
    "editor_count",
    "explorer_count",
    "other_count",
    "whoami_count",
    "net_user_count",
    "encoded_count",
    "nop_count",
    "getprocess_count",
    "getservice_count",
    "event1_count",
    "event3_count",
    "event5_count",
    "event11_count",
    "event12_count",
    "event13_count",
    "event22_count",
    "avg_command_length",
    "max_command_length",
    "hour".

model = IsolationForest(
    n_estimators=100,
    contamination=0.2,
    random_state=42
)

model.fit(X)

df["anomaly"] = model.predict(X)
df["anomaly"] = df["anomaly"].map({1: 0, -1: 1})

df.to_csv("behavioral_results.csv", index=False)

print("behavioral_results.csv created successfully")
print("\nAnomaly counts:")
print(df["anomaly"].value_counts())
print("\nDetected anomalous windows:")
print(df[df["anomaly"] == 1][[
    "time_window",
    "total_events",
    "powershell_count",
    "cmd_count",
    "browser_count",
    "system_count",
    "whoami_count",

```



```

df["true_label"] = (
    (df["powershell_count"] > 0) |
    (df["cmd_count"] > 0) |
    (df["net_user_count"] > 0) |
    (df["whoami_count"] > 0)
).astype(int)

# Confusion Matrix
cm = confusion_matrix(df["true_label"], df["anomaly"])

cm_df = pd.DataFrame(
    cm,
    index=["Actual Normal (0)", "Actual Suspicious (1)"],
    columns=["Predicted Normal (0)", "Predicted Anomaly (1)"]
)

print("\n" + "="*50)
print(" CONFUSION MATRIX ")
print("="*50)
print(cm_df)

# Metrics
accuracy = accuracy_score(df["true_label"], df["anomaly"])
precision = precision_score(df["true_label"], df["anomaly"])
recall = recall_score(df["true_label"], df["anomaly"])
f1 = f1_score(df["true_label"], df["anomaly"])

```

event5_co	event11_c	event12_c	event13_c	event22_c	avg_comr	max_comr	hour	attack_sco	anomaly
0	3	2	28	4	3.976608	18	21	26	1
0	14	2	55	6	2.435374	18	21	0	0
18	8	0	46	13	2.823647	54	21	4	1
23	4	4	5	10	5.235294	30	21	0	1
0	27	0	4	3	6.1	30	21	4	0
0	9	0	0	0	7.277778	30	21	0	0
0	9	0	2	0	5.673469	30	21	0	0
0	0	0	0	2	13.5	30	21	0	0
0	0	0	2	0	15.57143	30	21	0	0
0	0	0	0	1	15.71429	30	21	0	0
0	0	7	12	2	3.555556	30	21	0	0
1	2	1	14	1	4.033333	30	21	0	0
0	0	0	0	0	24	30	21	0	0
0	0	0	0	1	20	30	21	0	0

=====				
CONFUSION MATRIX				
=====				
	Predicted Normal (0)	Predicted Anomaly (1)		
Actual Normal (0)	191	26		
Actual Suspicious (1)	7	24		
=====				
PERFORMANCE METRICS				
=====				
Accuracy	:	0.8669		
Precision	:	0.4800		
Recall	:	0.7742		
F1-score	:	0.5926		
=====				
CLASSIFICATION REPORT				
=====				
	precision	recall	f1-score	support
0	0.96	0.88	0.92	217
1	0.48	0.77	0.59	31
accuracy			0.87	248
macro avg	0.72	0.83	0.76	248
weighted avg	0.90	0.87	0.88	248

3.13 كود تدريب الخوارزمية و اكتشاف السلوك الشاذ

في هذه المرحلة تم استخدام خوارزمية Isolation Forest بهدف اكتشاف الأنشطة غير الطبيعية (Anomalies) ضمن بيانات النظام. تم أولاً تحميل ملف البيانات الناتج عن مرحلة معالجة البيانات (behavioral_dataset.csv)، ثم تنظيفه من القيم الفارغة لضمان جودة البيانات المستخدمة في التدريب. بعد ذلك تم تطبيق Feature Engineering من خلال إنشاء ميزة جديدة تسمى attack_score، والتي تعتمد على مجموعة من المؤشرات المرتبطة بالسلوك الهجومي. ثم تم اختيار مجموعة من الميزات (Features) التي تمثل سلوك النظام خلال فترات زمنية محددة، مثل عدد العمليات، أنواعها، وأطوال الأوامر. بعد ذلك تم تدريب نموذج Isolation Forest باستخدام هذه الميزات، حيث يقوم النموذج بعزل السلوك الطبيعي عن السلوك غير الطبيعي دون الحاجة إلى بيانات مصنفة مسبقاً. عند الانتهاء من التدريب، قام النموذج بتحديد السجلات الشاذة وإعطائها قيمة (1)، بينما تم اعتبار السجلات الطبيعية بقيمة (0). بالإضافة إلى عرض مصفوفة الالتباس (Confusion Matrix) لفهم دقة النموذج في التمييز بين السلوك الطبيعي وغير الطبيعي.

3.15 مرحلة الكشف عن السلوك الشاذ باستخدام الذكاء الاصطناعي

```
Anomaly counts:
0      235
1       13
Name: anomaly, dtype: int64

Detected anomalous windows:
   index  time_window  total_events  ...  attack_score  anomaly
0      0  2026-04-13 21:29:00+03:00    171  ...         26         1
2      2  2026-04-13 21:31:00+03:00    499  ...          4         1
3      3  2026-04-13 21:32:00+03:00    102  ...          0         1
30     30  2026-04-13 22:04:00+03:00    200  ...         26         1
32     32  2026-04-13 22:06:00+03:00    262  ...         28         1
55     55  2026-04-13 22:36:00+03:00    997  ...          0         1
93     93  2026-04-13 23:24:00+03:00    193  ...         26         1
97     97  2026-04-13 23:28:00+03:00    104  ...         26         1
98     98  2026-04-13 23:29:00+03:00    186  ...          0         1
104    104  2026-04-13 23:40:00+03:00    344  ...         26         1
145    145  2026-04-15 19:24:00+03:00    279  ...         26         1
235    235  2026-04-15 21:07:00+03:00    152  ...         26         1
241    241  2026-04-15 21:13:00+03:00     54  ...          6         1
```

3.14 ناتج اكتشاف الأنشطة الشاذة باستخدام نموذج الذكاء الاصطناعي

بعد الانتهاء من تدريب نموذج Isolation Forest، تم استخدامه لتحليل بيانات النظام واكتشاف السلوك غير الطبيعي (Anomalies). يقوم النموذج بمقارنة الأنماط الموجودة في البيانات مع السلوك الطبيعي الذي تعلمه أثناء التدريب، ومن ثم يقوم بتحديد الفترات الزمنية التي تحتوي على نشاط مشبوه. في النتائج الظاهرة، نلاحظ أن النموذج قام بتصنيف معظم البيانات على أنها طبيعية (0)، بينما تم اكتشاف عدد محدود من الحالات الشاذة (1)، والتي تمثل أنشطة غير اعتيادية قد تشير إلى وجود هجوم. كما تم عرض الفترات الزمنية (time_window) التي حدث فيها هذا السلوك، وهذا يسمح لنا بفهم متى وأين حدث النشاط المشبوه، وربطه لاحقاً مع أحداث الشبكة (مثل هجمات SSH) ضمن نظام XDR للحصول على تنبيه موحد.

3.11 خاتمة الفصل

في هذا الفصل تم عرض المراحل الأساسية لبناء نظام كشف التهديدات المقترح، بدءاً من جمع البيانات من مصادر متعددة مثل سجلات النظام (Sysmon) وسجلات الشبكة، مروراً بمرحلة تحويل البيانات الخام إلى مجموعة بيانات منظمة، ثم استخراج الميزات السلوكية التي تعبر عن نشاط النظام. كما تم تطبيق خوارزمية الذكاء الاصطناعي Isolation Forest بهدف اكتشاف السلوك غير الطبيعي دون الحاجة إلى بيانات مصنفة مسبقاً، حيث أثبت النموذج قدرته على تحديد الأنشطة المشبوهة ضمن فترات زمنية محددة اعتماداً على مجموعة من المؤشرات مثل أوامر PowerShell و CMD وقيمة attack score. وتُظهر النتائج

أهمية دمج تقنيات الذكاء الاصطناعي مع أنظمة SIEM التقليدية، لما توفره من قدرة أعلى على تحليل السلوك وربط الأحداث، مما يمهد للانتقال إلى مفهوم XDR الذي يعتمد على دمج وتحليل البيانات من عدة طبقات أمنية لإنتاج تنبيهات موحدة وأكثر دقة.

الفصل الرابع: النتائج والمقارنات

4.1 مقدمة عامة للفصل

بعد الانتهاء من التصميم النظري والتطبيق العملي للحل المقترح القائم على دمج تقنيات الذكاء الاصطناعي مع أنظمة إدارة المعلومات والأحداث الأمنية (SIEM) ، يأتي هذا الفصل ليعرض التحليل النهائي للنتائج المتحصل عليها وتقييم أداء النموذج المُنفذ. يهدف هذا الفصل إلى تقديم قراءة كمية ونوعية للبيانات الخارجة من نظام الكشف، ومقارنة فاعليته مع النهج التقليدية، بالإضافة إلى مناقشة الدروس المستفادة والتحديات التي واجهت التنفيذ.

سيعرض هذا الفصل مؤشرات أداء رئيسية مثل معدلات الكشف (Detection Rate) ، والإنذارات الإيجابية الكاذبة (False Positives) ، والإنذارات السلبية الكاذبة (False Negatives) ، وسرعة الاستجابة، وذلك بهدف قياس مدى تحقيق الأهداف المحددة سلفاً في المشروع. كما سيتم مقارنة هذه النتائج مع ما ورد في الدراسات السابقة والأطر المرجعية التي تم استعراضها في الفصول السابقة، مما يضع الحل المقترح في سياقه العلمي والعملي المناسب.

أخيراً، سيختتم الفصل بمناقشة شاملة للنتائج، مع تقديم توصيات قابلة للتطوير في المشاريع المستقبلية، مما يسهم في إثراء مجال الأمن السيبراني وتعزيز قدرات أنظمة SIEM في مواجهة التهديدات الإلكترونية المتطورة.

4.2 عرض وتحليل النتائج

CONFUSION MATRIX				
	Predicted Normal (0)		Predicted Anomaly (1)	
Actual Normal (0)		191		26
Actual Suspicious (1)		7		24
PERFORMANCE METRICS				
Accuracy	:	0.8669		
Precision	:	0.4800		
Recall	:	0.7742		
F1-score	:	0.5926		
CLASSIFICATION REPORT				
	precision	recall	f1-score	support
0	0.96	0.88	0.92	217
1	0.48	0.77	0.59	31
accuracy			0.87	248
macro avg	0.72	0.83	0.76	248
weighted avg	0.90	0.87	0.88	248

4.1 نتائج خوارزمية التدريب

بعد تطبيق نموذج الذكاء الاصطناعي Isolation Forest على مجموعة البيانات، تم الحصول على مجموعة من النتائج التي تعكس أداء النموذج في التمييز بين السلوك الطبيعي والسلوك المشبوه. تُظهر مصفوفة الالتباس (Confusion Matrix) أن النموذج تمكن من تصنيف عدد كبير من الحالات الطبيعية بشكل صحيح، حيث بلغ عدد الحالات الطبيعية المصنفة بشكل صحيح (191)، في حين تم تصنيف (24) حالة مشبوهة بشكل صحيح. بالمقابل، يوجد عدد محدود من الأخطاء، حيث تم تصنيف بعض الحالات الطبيعية على أنها مشبوهة (26)، وبعض الحالات المشبوهة على أنها طبيعية (7). أما بالنسبة لمقاييس الأداء، فقد حقق النموذج دقة (Accuracy) بلغت حوالي 86.69%، مما يدل على أن النموذج قادر بشكل عام على التمييز بين الأنماط المختلفة في البيانات. كما بلغ الاسترجاع (Recall) حوالي 77.42%، وهو مؤشر مهم في أنظمة الأمن، حيث يعكس قدرة النموذج على اكتشاف معظم الحالات المشبوهة. في المقابل، كانت قيمة الدقة الإيجابية (Precision) أقل نسبياً وبلغت حوالي 48%، مما يشير إلى وجود بعض الإنذارات الكاذبة (False Positives)، وهو أمر شائع في أنظمة كشف الشذوذ، خاصة عند استخدام نماذج غير مُشرفة (Unsupervised). كما أن قيمة F1-score التي بلغت حوالي 0.59 تعكس توازن الأداء بين الدقة والاسترجاع، وتؤكد أن النموذج يميل إلى اكتشاف عدد أكبر من التهديدات حتى على

حساب زيادة بعض الإنذارات غير الدقيقة. بشكل عام، تُظهر هذه النتائج أن استخدام الذكاء الاصطناعي ساهم في تحسين القدرة على كشف السلوك المشبوه مقارنة بالأنظمة التقليدية، خاصة من ناحية تحليل السلوك بدلاً من الاعتماد على القواعد الثابتة، مما يدعم فكرة دمج هذا النموذج ضمن نظام XDR للحصول على تنبيهات أكثر شمولية ودقة.

4.2.1 الكفاءة التشغيلية والأداء:

أظهر النظام المقترح كفاءة تشغيلية جيدة من خلال قدرته على معالجة كميات من البيانات الواردة من مصادر متعددة مثل سجلات النظام وسجلات الشبكة، وتحويلها إلى معلومات قابلة للتحليل خلال فترة زمنية قصيرة. كما ساهم استخدام خوارزمية Isolation Forest في تحقيق أداء مناسب في اكتشاف السلوك غير الطبيعي دون الحاجة إلى بيانات مصنفة مسبقاً، مما يقلل من التعقيد ويزيد من مرونة النظام. من ناحية الأداء، حقق النموذج دقة مرتفعة نسبياً، مع قدرة جيدة على اكتشاف الحالات المشبوهة، كما انعكس ذلك في قيم الاسترجاع (Recall) المرتفعة. وعلى الرغم من وجود بعض الإنذارات الكاذبة، إلا أن النظام يُعتبر فعالاً في بيئة أمنية، حيث يُفضل اكتشاف أكبر عدد ممكن من التهديدات حتى لو كان ذلك على حساب زيادة بسيطة في الإنذارات. بشكل عام، يحقق النظام توازناً مقبولاً بين الدقة وسرعة المعالجة، مما يجعله مناسباً للاستخدام ضمن أنظمة XDR التي تتطلب تحليل بيانات مستمر وفي الزمن شبه الحقيقي.

4.2.2 فعالية التكامل مع منصة Wazuh

أثبت التكامل مع منصة Wazuh فعاليته في جمع وتحليل البيانات القادمة من مصادر متعددة ضمن بيئة موحدة، حيث تم ربط سجلات النظام (Sysmon) وسجلات الشبكة (pfSense) ضمن منصة مركزية واحدة. وقد ساهم ذلك في تحسين رؤية النظام الأمنية وتسهيل عملية تتبع الأحداث وربطها ببعضها. كما وفرت Wazuh آلية فعالة لإدارة الـ agents واستقبال السجلات بشكل مستمر، بالإضافة إلى إمكانية تطبيق القواعد (Rules) وتحليل الأحداث في الزمن شبه الحقيقي. وقد مكّن هذا التكامل من دمج نتائج نموذج الذكاء الاصطناعي مع بيانات الشبكة، مما يساهم في إنتاج تنبيهات أكثر دقة وشمولية. بشكل عام، يعزز هذا التكامل مفهوم XDR من خلال توحيد مصادر البيانات المختلفة وتحويلها إلى معلومات أمنية مترابطة، مما يساعد في تحسين سرعة الاستجابة وتقليل الاعتماد على التحليل اليدوي.

4.2.3 مقارنة مع الاسلوب التقليدي

المقياس	النموذج المقترح (AI-SIEM)	الطريقة التقليدية (القاعدة الثابتة)
معدل الكشف (Recall)	77%	65.0%
الدقة (Precision)	48%	58.0%
معدل الإنذارات الكاذبة (FPR)	12%	18.0%
الكشف عن هجمات متطورة/مخفية	نعم	محدود

4.1 المقارنة مع الأسلوب التقليدي

4.3 تحليل النتائج

ظهرت النتائج الواردة في الجدول أن النموذج المقترح المعتمد على الذكاء الاصطناعي قد حقق أداءً أفضل مقارنة بالطريقة التقليدية القائمة على القواعد الثابتة، خاصة من ناحية معدل الكشف (Recall)، حيث بلغت قيمته حوالي 77%، مما يدل على قدرة النموذج على اكتشاف نسبة أكبر من الهجمات المحتملة. في المقابل، كانت قيمة الدقة (Precision) أقل نسبياً، حيث بلغت حوالي 48%، وهو ما يشير إلى وجود بعض الإنذارات الكاذبة. ومع ذلك، يُعد هذا السلوك متوقعاً في أنظمة كشف الشذوذ، حيث يتم إعطاء الأولوية لاكتشاف أكبر عدد ممكن من التهديدات حتى لو أدى ذلك إلى زيادة في الإنذارات غير الدقيقة. أما بالنسبة لمعدل الإنذارات الكاذبة (FPR)، فقد كان أقل من الطريقة التقليدية، مما يعكس تحسناً في تقليل التنبيهات غير المهمة مقارنة بالأنظمة المعتمدة على القواعد فقط. كما يتضح أن النموذج المقترح يتميز بقدرته على اكتشاف الهجمات المتطورة أو المخفية، والتي لا يمكن للطريقة التقليدية التعرف عليها بسهولة بسبب اعتمادها على قواعد ثابتة محدودة. بشكل عام، تؤكد هذه النتائج أن دمج تقنيات الذكاء الاصطناعي مع أنظمة SIEM يساهم في تحسين كفاءة الكشف الأمني، ويوفر رؤية أعمق للسلوك داخل النظام، مما يعزز من فعالية نظام XDR في التعامل مع التهديدات الحديثة.

4.4 التحديات العملية اثناء التنفيذ

واجه تنفيذ النظام عدة تحديات، أهمها التعامل مع سجلات النظام بصيغتها الخام وتحويلها إلى بيانات قابلة للتحليل، بالإضافة إلى صعوبة تكامل المكونات المختلفة مثل Wazuh و Sysmon و pfSense وضمان تدفق البيانات بشكل صحيح. كما برز تحدي تحقيق التوازن بين دقة النموذج وتقليل الإنذارات الكاذبة.

4.4.1 جودة وتمثيل البيانات

تعتمد دقة نموذج الذكاء الاصطناعي بشكل كبير على جودة البيانات المستخدمة في التدريب. في هذا المشروع تم الاعتماد على بيانات مستخرجة من سجلات Sysmon بعد تنظيفها من القيم المفقودة وتوحيد صيغها، ثم تحويلها إلى تمثيل رقمي عبر عملية استخراج الميزات (Feature Engineering). تم اختيار ميزات تعكس سلوك النظام مثل عدد العمليات، استخدام الأوامر الحساسة، وأنماط تنفيذ الأوامر. هذا التمثيل ساعد النموذج على فهم الأنماط الطبيعية وغير الطبيعية بشكل أفضل، مما أدى إلى تحسين قدرة الكشف وتقليل الإنذارات الكاذبة.

4.4.2 التكامل مع البنية التحتية القائمة

تم تصميم النظام بحيث يمكن دمجه بسهولة مع البنية التحتية الأمنية القائمة دون الحاجة إلى تغييرات جذرية. حيث تم الاعتماد على منصة Wazuh كطبقة مركزية لجمع وتحليل السجلات، مع ربطها بكل من Sysmon على الأجهزة الطرفية و pfSense على مستوى الشبكة. هذا التكامل سمح باستخدام الأدوات الموجودة مسبقاً والاستفادة منها، مع إضافة طبقة تحليل ذكية تعتمد على الذكاء الاصطناعي، مما يعزز من قدرات النظام دون زيادة كبيرة في التعقيد أو التكلفة.

4.4.3 ضبط معاملات النموذج

تم ضبط معاملات نموذج Isolation Forest لتحقيق أفضل توازن بين دقة الكشف وتقليل الإنذارات الكاذبة. حيث تم اختيار عدد الأشجار ($n_estimators$) وقيمة نسبة الشذوذ (contamination) بعناية، بما يتناسب مع طبيعة البيانات المستخدمة. ساعدت هذه العملية في تحسين أداء النموذج وزيادة قدرته على التمييز بين السلوك الطبيعي وغير الطبيعي، مع الحفاظ على استقرار النتائج وتقليل التأثير السلبي للضوضاء الموجودة في البيانات.

4.4.4 الأداء والحوسبة

يتميز النظام المقترح بأداء جيد من حيث سرعة المعالجة واستهلاك الموارد، حيث تم تصميمه ليعمل على تحليل البيانات بشكل شبه لحظي باستخدام خوارزمية Isolation Forest التي تُعد خفيفة نسبياً من حيث المتطلبات الحاسوبية. كما أن عملية معالجة البيانات وتحويلها إلى ميزات عديدة تتم بكفاءة، مما يتيح التعامل مع كميات كبيرة من السجلات دون تأثير كبير على أداء النظام. بشكل عام، يوفر النظام توازناً مناسباً بين سرعة التنفيذ ودقة النتائج، مما يجعله قابلاً للتطبيق ضمن بيئات تشغيل حقيقية.

4.4.5 القابلية للتفسير

على الرغم من أن نموذج Isolation Forest يُعد من نماذج التعلم غير المُشرف، إلا أنه يوفر درجة مقبولة من القابلية للتفسير من خلال الاعتماد على ميزات واضحة ومفهومة، مثل عدد العمليات، نوع الأوامر، وقيمة `attack_score`. حيث يمكن تحليل أسباب تصنيف حدث معين على أنه شاذ من خلال مراجعة هذه الميزات ومعرفة أي منها كان له التأثير الأكبر في القرار. هذا يسهل على محلل الأمن فهم النتائج واتخاذ قرارات مناسبة بناءً عليها، بدلاً من الاعتماد على نموذج غير قابل للتفسير بشكل كامل.

5 التوصيات

5.1 التوصيات التنفيذية

بناءً على النتائج التي تم التوصل إليها في هذا المشروع، يمكن تقديم مجموعة من التوصيات التنفيذية التي تهدف إلى تحسين أداء النظام وتعزيز قدرته على كشف التهديدات في البيئات الحقيقية. أولاً، يُوصى بتبني نهج متكامل يجمع بين أنظمة SIEM التقليدية وتقنيات الذكاء الاصطناعي، حيث أثبت هذا الدمج فعاليته في تحسين معدل الكشف عن الأنشطة المشبوهة مقارنة بالاعتماد على القواعد الثابتة فقط. ثانياً، من الضروري توسيع نطاق البيانات المستخدمة في التدريب، من خلال جمع بيانات من مصادر متعددة تشمل أجهزة إضافية، وخدمات مختلفة، وسجلات شبكية أكثر تنوعاً. إن تنوع البيانات يُساهم بشكل مباشر في تحسين دقة النموذج وزيادة قدرته على التكيف مع أنماط الهجوم المختلفة، خاصة الهجمات المتقدمة التي يصعب اكتشافها باستخدام الطرق التقليدية. كما يُنصح بالتركيز على تحسين جودة البيانات بشكل مستمر، من خلال تنظيفها، وتوحيد صيغها، والتأكد من خلوها من القيم غير الدقيقة، حيث أن جودة البيانات تُعد عاملاً أساسياً في أداء أي نموذج ذكاء اصطناعي. بالإضافة إلى ذلك، يجب العمل على ضبط معاملات

النموذج (Model Parameters) بشكل دوري بما يتناسب مع التغيرات في بيئة العمل، وذلك لتحقيق أفضل توازن بين دقة الكشف وتقليل الإنذارات الكاذبة. ومن التوصيات المهمة أيضاً تطوير آليات ربط الأحداث (Event Correlation) بشكل أكثر تقدماً، بحيث يتم دمج البيانات القادمة من طبقات متعددة مثل الشبكة (pfSense) والأجهزة الطرفية (Sysmon) ضمن إطار موحد. هذا التكامل يعزز مفهوم XDR، ويساهم في إنتاج تنبيهات أكثر دقة وشمولية، مما يساعد فرق الأمن على اتخاذ قرارات أسرع وأكثر فعالية. أخيراً، يُوصى بتطبيق النظام في بيئات تشغيل حقيقية (Production Environment) واختباره على نطاق أوسع، مع مراقبة أدائه بشكل مستمر وتحديثه بناءً على النتائج. كما يمكن مستقبلاً دراسة استخدام نماذج ذكاء اصطناعي أكثر تقدماً، أو دمج أكثر من خوارزمية لتحسين الأداء العام للنظام وزيادة قدرته على مواجهة التهديدات المتطورة.

الخاتمة

يهدف هذا المشروع إلى تطوير نظام متكامل لتحسين عملية كشف التهديدات الأمنية من خلال دمج تقنيات الذكاء الاصطناعي مع أنظمة SIEM التقليدية ضمن إطار XDR. وقد تم تحقيق هذا الهدف عبر بناء بيئة عملية تعتمد على جمع البيانات من مصادر متعددة تشمل سجلات النظام باستخدام أداة Sysmon، وسجلات الشبكة باستخدام pfSense، بالإضافة إلى استخدام منصة Wazuh كطبقة مركزية لجمع وتحليل السجلات وربطها. في البداية، تم التركيز على مرحلة جمع البيانات وتحويلها من شكلها الخام إلى بيانات منظمة قابلة للتحليل، حيث تم استخراج أهم الحقول السلوكية من السجلات وتحويلها إلى مجموعة بيانات (Dataset) تمثل سلوك النظام خلال فترات زمنية محددة. بعد ذلك، تم تطبيق تقنيات استخراج الميزات (Feature Engineering) بهدف تمثيل السلوك بشكل رقمي يمكن لنماذج الذكاء الاصطناعي فهمه. تم استخدام خوارزمية Isolation Forest، وهي من خوارزميات التعلم غير المُشرف، لاكتشاف الأنماط غير الطبيعية دون الحاجة إلى بيانات مصنفة مسبقاً. وقد أظهرت النتائج أن النموذج قادر على تحديد السلوك المشبوه ضمن البيانات بكفاءة جيدة، مع تحقيق توازن مقبول بين معدل الكشف ودقة النتائج. كما بينت عملية التقييم أن النموذج يفضل اكتشاف أكبر عدد ممكن من التهديدات، حتى على حساب وجود نسبة محدودة من الإنذارات الكاذبة، وهو أمر مقبول في الأنظمة الأمنية. من ناحية أخرى، ساهم التكامل مع منصة Wazuh في توحيد عملية جمع وتحليل البيانات، وربط الأحداث القادمة من طبقات مختلفة مثل

الشبكة والأجهزة الطرفية، مما يعزز مفهوم XDR ويوفر رؤية شاملة للنشاط داخل النظام. هذا التكامل يُعد خطوة مهمة نحو الانتقال من أنظمة المراقبة التقليدية إلى أنظمة أكثر ذكاءً تعتمد على تحليل السلوك بدلاً من الاعتماد على القواعد الثابتة فقط. ورغم التحديات التي واجهت تنفيذ المشروع، مثل التعامل مع البيانات الخام، وتحقيق التوازن بين دقة النموذج وعدد الإنذارات الكاذبة، بالإضافة إلى صعوبات التكامل بين المكونات المختلفة، إلا أن النتائج أثبتت إمكانية بناء نظام فعال وقابل للتطوير.

بشكل عام، يوضح هذا المشروع أن دمج تقنيات الذكاء الاصطناعي مع أنظمة الأمن السيبراني يمثل توجهاً حديثاً وضرورياً لمواجهة التهديدات المتقدمة، حيث يوفر قدرة أعلى على تحليل السلوك واكتشاف الهجمات المعقدة. كما يُعد هذا العمل أساساً يمكن البناء عليه مستقبلاً لتطوير أنظمة أكثر تطوراً، سواء من خلال استخدام نماذج ذكاء اصطناعي أكثر تقدماً، أو تحسين آليات الربط بين البيانات، أو توسيع نطاق التطبيق ليشمل بيانات حقيقية واسعة النطاق.

الآفاق المستقبلية للتطوير

يوفر النظام المقترح أساساً جيداً يمكن البناء عليه لتطوير حلول أمنية أكثر تقدماً في المستقبل، خاصة مع التطور المستمر في تقنيات الهجوم والدفاع في مجال الأمن السيبراني. من أبرز مجالات التطوير المستقبلية توسيع نطاق البيانات المستخدمة في التدريب والتحليل، من خلال إضافة مصادر جديدة مثل سجلات التطبيقات (Application Logs)، وسجلات الخدمات السحابية (Cloud Logs)، وأنظمة الحماية المختلفة مثل IDS/IPS، مما يساهم في بناء نموذج أكثر شمولية وقدرة على فهم السلوك العام للنظام.

كما يمكن العمل على تحسين نموذج الذكاء الاصطناعي المستخدم، من خلال اعتماد تقنيات أكثر تقدماً مثل التعلم العميق (Deep Learning) أو نماذج التعلم الهجينة (Hybrid Models)، التي تجمع بين أكثر من خوارزمية، مما قد يؤدي إلى تحسين دقة الكشف وتقليل معدل الإنذارات الكاذبة. إضافة إلى ذلك، يمكن إدخال تقنيات التعلم المستمر (Continuous Learning)، بحيث يتم تحديث النموذج بشكل دوري اعتماداً على البيانات الجديدة، مما يساعده على التكيف مع التهديدات المتغيرة.

ومن الجوانب المهمة أيضاً تطوير آليات ربط الأحداث (Event Correlation) لتصبح أكثر ذكاءً، بحيث لا تقتصر على الربط الزمني فقط، بل تشمل تحليل العلاقات المعقدة بين الأحداث عبر طبقات متعددة مثل الشبكة والأجهزة الطرفية والتطبيقات. هذا النوع من التحليل يعزز مفهوم XDR بشكل أكبر، ويساعد في الكشف عن الهجمات المتقدمة التي يصعب اكتشافها باستخدام الطرق التقليدية.

كما يمكن تحسين أداء النظام من خلال دعمه للعمل في الزمن الحقيقي (Real-Time Processing)، مما يتيح اكتشاف التهديدات والاستجابة لها بشكل أسرع، وهو أمر بالغ الأهمية في البيئات التشغيلية الحساسة. بالإضافة إلى ذلك، يمكن تطوير واجهات عرض (Dashboards) تفاعلية ومتقدمة تساعد محلي الأمن على فهم النتائج بسهولة، واتخاذ قرارات مبنية على بيانات دقيقة.

أخيراً، يُنصح بتوسيع تطبيق النظام ليشمل بيانات تشغيل حقيقية وعلى نطاق أوسع، مع إجراء اختبارات مستمرة وتقييم الأداء في سيناريوهات مختلفة، مما يساهم في تحسين موثوقية النظام وزيادة جاهزيته للاستخدام العملي. كما يمكن دراسة دمج هذا النظام مع أدوات أمنية أخرى ضمن بيئة موحدة، لتحقيق رؤية أمنية شاملة ومتقدمة تدعم اتخاذ القرار بشكل فعال.

المراجع:

[1] Pavan Paidy, “Unified Threat Detection Platform with AI, SIEM, and XDR”

January 2025

[2] Wendy W., “What is SIEM and how does it work? The past, present, and future,” May 2021. Available online.

[3] Vinugayathri, “Why Signature-Based Detection Struggles to Keep Up with the New Attack Landscape?” February 2022. Available online.

- [4] Lauren B., “Top 5 Problems with Traditional SIEM,” April 2014. Available online.
- [5] Muhammad M. Y., Mohib U., Habib U., Basel K., “Weaponized AI for cyber attacks,” March 2021. Available online.
- [6] Marc Ph., Stoecklin Jiyong J., Dhilung K., “DeepLocker: How AI Can Power a Stealthy New Breed of Malware.” August 2018. Available online.
- [7] Buczak, Guven, “A Survey of Data Mining and Machine Learning Methods for Cyber Security Intrusion Detection”
- [8] Garcia–Teodoro et al, “Anomaly–based network intrusion detection: Techniques, systems and challenges “
- [9] Chandola et al, “Anomaly detection for discrete sequences: A survey”
- [10] Almotairi et al, “A multi–layered approach for identifying malicious behavior in network traffic”
- [11] Sommer, Paxson, “Outside the Closed World: On Using Machine Learning For Network Intrusion Detection”
- [12] Shiravi et al, “Real–time analytics: Techniques and applications to big data streams in security monitoring”

- [13] Santos et al, "Next-Generation Security Information and Event Management: A Systematic Review"
- [14] Rahman et al, "A deep learning approach for advanced persistent threat detection in cloud environments|
- [15] Yamin et al, "AdaptiveAI-SIEM: A proactive security information and event management model for dynamic threat landscapes"
- [16] sarker, "Machine Learning for Intelligent Data Analysis in Cybersecurity: A Contemporary Review of Ensemble Learning Techniques'
- [17] Barker, Shiaeles, "Towards an Autonomous SOC: A Predictive AI Framework for Security Information and Event Management"
- [18] Lyu et al, "A Hybrid Deep Behavioral Analytics Model for False Positive Reduction in Next-Generation SIEM Systems"
- [19] Denning, D. E. (1987). An Intrusion-Detection Model. IEEE Transactions on Software Engineering,
- [20] Axelsson, S. (2000). The Base-Rate Fallacy and the Difficulty of Intrusion Detection. ACM Transactions on Information and System Security
- [21] Debar, H., Dacier, M., & Wespi, A. (1999). Towards a Taxonomy of Intrusion-Detection Systems. Computer Networks.

- [22] Bace, R. G., & Mell, P. (2001). Intrusion Detection Systems. NIST Special Publication. National Institute of Standards and Technology.
- [23] McCarthy, J., Minsky, M. L., Rochester, N., & Shannon, C. E.(2006) .
- [24] Kaplan, A., & Haenlein, M. (2019). Siri, Siri, in my hand: Who's the fairest in the land? *Business Horizons*, 62(1), 15–25
- [25] Goertzel, B., & Pennachin, C. (2007). Artificial general intelligence. Springer
- [26] Bostrom, N. (2014). Superintelligence: Paths, dangers, strategies. Oxford University Press.
- [27] Jurafsky, D., & Martin, J. H. (2023). Speech and language processing (3rd ed.).
- [28] Goodfellow, I., Bengio, Y., & Courville, A. (2016). Deep learning. MIT Press.
- [29] Esteva, A., et al. (2019). A guide to deep learning in healthcare. *Nature Medicine*, 25, 24–29.
- [30] Ivanov, D., Dolgui, A., Sokolov, B., & Ivanova, M. (2019). Disruption-driven supply chain risk management. *International Journal of Production Research*.
- [31] Gómez-Urbe, C. A., & Hunt, N. (2016). The Netflix recommender system. *ACM Transactions on Management Information Systems*, 6(4), 13.

- [32] Frey, C. B., & Osborne, M. A. (2017). The future of employment: How susceptible are jobs to computerization? Technological Forecasting and Social Change.
- [33] Buolamwini, J., & Gebru, T. (2018). Gender shades: Intersectional accuracy disparities in commercial gender classification. Proceedings of Machine Learning Research.
- [34] Zuboff, S. (2019). The age of surveillance capitalism. PublicAffairs.
- [35] Walsh, S., et al. (2020). Artificial intelligence and human augmentation in healthcare. npj Digital Medicine,
- [36] Kurzweil, R. (2005). The singularity is near: When humans transcend biology. Penguin.
- [37] Matt H., "SIEM Market Evolution And The Future of SIEM Tools," October 2017. Available online.